UNIVERSIDAD TECNICA
FEDERICO SANTA MARIA

DEPARTAMENTO DE
ELECTRONICA

Detección y localización de patologías torácicas en radiografías mediante Deep Learning

Documento de Avance de la Solución — Hito 2

Fecha	6 de noviembre de 2026
Integrantes:	Benjamin Esteban Arias Vega
	Karime Andrea Jarufe Escobar
	Nicolas Eduardo Severino Palma
	Hans David Varela Antilao
Asignatura:	TEL328
Profesor:	Marcos Zúñiga
Versión:	2.0 (Hito 2)

Índice

1 Introducción **4**
1.1 Resumen del avance . . . 4

2 Planificación del Proyecto **4**
2.1 Objetivo General (Goal) . . . 4
2.2 Objetivos Específicos . . . 4
2.3 Actividades y Milestones . . . 5
2.4 Tareas y entregables . . . 5
2.5 Carta Gantt . . . 6
2.6 Nivel de madurez tecnológica . . . 6

3 Solución desarrollada **7**
3.1 Scripts del proyecto . . . 7
3.2 Preparación de datos . . . 7
3.3 Modelo y entrenamiento . . . 7
3.4 Localización . . . 8
3.5 Ambiente de desarrollo . . . 8

4 Resultados **8**
4.1 Verificación y estadísticas del dataset . . . 8
4.2 División por paciente . . . 9
4.3 Pesos por clase . . . 10
4.4 Entrenamiento de prueba . . . 10

5 Arquitectura implementada **10**
5.1 Diagrama de arquitectura . . . 10
5.2 Módulos y código . . . 11
5.3 Cambios respecto del diseño del Hito 1 . . . 11
5.4 Estado de los requisitos . . . 12

6 Interfaz implementada **12**

7 Pruebas **14**
7.1 Pruebas automatizadas . . . 14
7.2 Estado del plan de pruebas . . . 15

8 Seguimiento y próximos pasos **15**
8.1 Tareas del siguiente ciclo (semana 15) . . . 15
8.2 Impedimentos y riesgos . . . 15
8.3 Próximos hitos . . . 15

9 Conclusiones **16**

10 Referencias **16**

A Guía de ejecución **16**

B Índice de evidencias **16**

Índice de figuras

1 Número de hallazgos por imagen . . . 8
2 Matriz de co-ocurrencia (lift) entre las 14 patologías . . . 9
3 Diagrama de arquitectura del sistema . . . 11
4 Resultado del análisis con cajas y umbral 0,30 . . . 12
5 Mapa de calor de Grad-CAM y archivos exportados . . . 13
6 Selección de patologías, cambio de umbral y rechazo de un archivo no permitido . . . 13
7 Resumen exportado en CSV . . . 13
8 Consola de la demostración: modelo real (`RX_USE_STUBS=0`) . . . 14

Índice de cuadros

1 Objetivos específicos y criterios de éxito . . . 4
2 Actividades y milestones . . . 5
3 Tareas, autores y entregables . . . 5
4 Carta Gantt . . . 6
5 Scripts de la solución . . . 7
6 Pares de patologías con mayor lift . . . 9
7 Resultado de la división del dataset . . . 9
8 Frecuencia y peso por clase en el conjunto de entrenamiento . . . 10
9 Métricas del entrenamiento de prueba (`log_etapa1.csv`) . . . 10
10 Implementación de los módulos . . . 11
11 Decisiones tomadas durante la implementación . . . 11
12 Estado de los requisitos en el corte de la semana 14 . . . 12
13 Interacciones implementadas . . . 14
14 Resultado de las pruebas automatizadas por archivo . . . 14
15 Avance del plan de pruebas del Hito 1 . . . 15
16 Impedimentos y riesgos . . . 15
17 Evidencias del Hito 2 en la carpeta `evidencias/` . . . 16

1. Introducción

El proyecto desarrolla un sistema que recibe una radiografía de tórax en formato DICOM, la procesa con un modelo de Deep Learning y entrega las patologías probables y su ubicación aproximada sobre la imagen. El modelo se entrena con el dataset público **NIH ChestX-ray14** [1], que contiene 112.120 radiografías frontales de 30.805 pacientes, con etiquetas para 14 patologías.

El sistema es una **herramienta de apoyo y prototipo académico**, no un dispositivo de diagnóstico: cualquier resultado debe ser revisado por un profesional de la salud.

Este documento corresponde al Hito 2 (corte: semana 14, del 02/11 al 06/11) y continúa el Documento de Análisis y Diseño del Hito 1, al que se remite para el diagnóstico del problema, el estado del arte, los perfiles de usuario y el diseño original. Aquí se describe lo implementado, los resultados obtenidos, las pruebas ejecutadas y el trabajo pendiente. Las evidencias citadas están en la carpeta `evidencias/` de la rama `hito-2` del repositorio del proyecto, y su índice se encuentra en el Anexo B.

1.1. Resumen del avance

- **Implementado:** verificación del dataset, división por paciente, estadísticas, pesos por clase, subconjunto de prueba, script de entrenamiento y aplicación con lector DICOM, inferencia, Grad-CAM, cajas delimitadoras y exportación.
- **Resultado del modelo:** solo existe un modelo de prueba, entrenado con 2.000 imágenes durante 2 épocas, con AUC de validación de 0,61. Sirve para comprobar que el flujo funciona, no como medida de desempeño final.
- **Pruebas:** 26 de 26 pruebas automatizadas aprobadas, sin depender del modelo entrenado.
- **Pendiente:** entrenamiento completo con las 76.277 imágenes de entrenamiento, evaluación AUC-ROC en el conjunto de prueba, evaluación IoU de las cajas y pruebas de sistema y usabilidad.

2. Planificación del Proyecto

La planificación sigue la estructura presentada en el material del curso *Elementos Iniciales de Planificación de Proyectos*: objetivo general, objetivos específicos, actividades, tareas con un entregable asociado y milestones. Los estados y porcentajes provienen de la Bitácora 2.

2.1. Objetivo General (Goal)

Desarrollar un sistema de apoyo al análisis de radiografías de tórax, basado en Deep Learning, que detecte patologías pulmonares y su ubicación a partir de una imagen DICOM, utilizando el dataset NIH ChestX-ray14.

2.2. Objetivos Específicos

Cada objetivo parte con un verbo de acción y se detalla según las partes propuestas en el material del curso. La población afectada es el equipo de desarrollo en O1 y O5, y los perfiles de usuario definidos en el Hito 1 en O2, O3 y O4.

Cuadro 1: Objetivos específicos y criterios de éxito

Objetivo (qué)	Cuándo	Cómo y criterio	Nivel de éxito	Avance
O1. Analizar y preparar el dataset NIH ChestX-ray14 con división por paciente	S12	Scripts de verificación, división y estadísticas; evidencia en logs y reportes	Conteos oficiales coinciden y 0 pacientes en común entre conjuntos (PM1)	100 %
O2. Entrenar y evaluar un clasificador multi-etiqueta de 14 patologías	S16	DenseNet-121 con transferencia de aprendizaje; AUC-ROC por patología en el conjunto de prueba	AUC-ROC reportado para las 14 patologías y promedio cercano a la literatura (PM2). Meta numérica por fijar tras el entrenamiento completo (RNF8)	67 %
O3. Implementar y evaluar la localización de regiones afectadas	S16	Grad-CAM y conversión a cajas; comparación con las 984 cajas reales	IoU y proporción de aciertos reportados a distintos umbrales (PM3)	67 %
O4. Desarrollar una aplicación que reciba DICOM y muestre patologías y ubicación	S17	Aplicación local con los módulos integrados; pruebas de sistema	Resultado en menos de 10 s (RNF1) y en no más de 3 pasos (RNF2)	100 %
O5. Diseñar y ejecutar el plan de pruebas	S18	Pruebas de modelo, unitarias, de sistema y de usabilidad	Todas las pruebas PM, PU y PS ejecutadas e informadas	67 %

El avance de O4 corresponde a la implementación e integración registradas en la Bitácora 2. Sus niveles de éxito se medirán con las pruebas PS1 y PS5, que siguen pendientes (sección 7).

2.3. Actividades y Milestones

Semanas y fechas según el calendario del curso. La participación corresponde a la propuesta del Hito 1.

Cuadro 2: Actividades y milestones

Elemento	Responsable	Participación equipo	Fecha comienzo	Fecha término	% avance
A1.1 Análisis del dataset (O1)	Nicolas Severino	25 % c/u	21/09 (S8)	02/10 (S9)	100 %
A1.2 Pipeline de datos (O1)	Benjamin Arias	25 % c/u	12/10 (S11)	23/10 (S12)	100 %
A2.1 Modelo base (O2)	Hans Varela	25 % c/u	12/10 (S11)	06/11 (S14)	83 %
A2.2 Ajuste y evaluación (O2)	Hans Varela	25 % c/u	02/11 (S14)	20/11 (S16)	50 %
A3.1 Localización con Grad-CAM (O3)	Karime Jarufe	25 % c/u	02/11 (S14)	20/11 (S16)	67 %
A4.1 Lectura y preprocesamiento de DICOM (O4)	Benjamin Arias	25 % c/u	12/10 (S11)	30/10 (S13)	100 %
A4.2 Interfaz gráfica (O4)	Karime Jarufe	25 % c/u	28/09 (S9)	27/11 (S17)	100 %
A5.1 Diseño de pruebas (O5)	Nicolas Severino	25 % c/u	28/09 (S9)	09/10 (S10)	100 %
A5.2 Ejecución de pruebas (O5)	Nicolas Severino	25 % c/u	02/11 (S14)	04/12 (S18)	33 %
G1.1 Documentación, seguimiento y presentaciones	Todo el equipo	25 % c/u	21/09 (S8)	04/12 (S18)	71 %
G1.2 Definición y delimitación del problema	Todo el equipo	25 % c/u	21/09 (S8)	02/10 (S9)	100 %
Milestone 1: Análisis y Diseño (documento, presentación y Bitácora 1)	Todo el equipo	25 % c/u	21/09 (S8)	09/10 (S10)	100 %
Milestone 2 (Bitácora 2): avance con modelo base y lector DICOM	Todo el equipo	25 % c/u	12/10 (S11)	06/11 (S14)	100 %
Milestone 3: sistema integrado con localización e interfaz	Todo el equipo	25 % c/u	02/11 (S14)	27/11 (S17)	60 %
Milestone 4: presentación en la Feria y evaluación final (Bitácora 3)	Todo el equipo	25 % c/u	23/11 (S17)	04/12 (S18)	0 %

El Milestone 2 se considera entregado con un modelo base de prueba y el lector DICOM. El entrenamiento completo sigue pendiente en la tarea T2.1.3.

2.4. Tareas y entregables

Según el material del curso, una tarea es válida solo si tiene un entregable asociado. Se usa el acuerdo de colores del curso: verde para completada, amarillo para asignada en el período o parcialmente lograda, y blanco para no asignada.

Cuadro 3: Tareas, autores y entregables

ID	Tarea	Autor(es)	Entregable	Avance
T1.1.1	Descargar el dataset y revisar su estructura y metadatos	Hans Varela	Dataset local e inventario de archivos	100 %
T1.1.2	Estadísticas de clases y matriz de co-ocurrencia	Hans Varela	Script, reporte y gráficos de distribución	100 %
T1.2.1	División por paciente y validación interna	Benjamin Arias	Script de división de datos	100 %
T1.2.2	Preprocesamiento (PRE) y aumento de datos	Benjamin Arias	Módulo PRE (código)	100 %
T2.1.1	Configurar TensorFlow/Keras y GPU de entrenamiento	Nicolas Severino	Guía de entorno y dependencias	100 %
T2.1.2	Clasificador DenseNet-121 con transferencia de aprendizaje	Nicolas Severino	Script del modelo (módulo CLS)	100 %

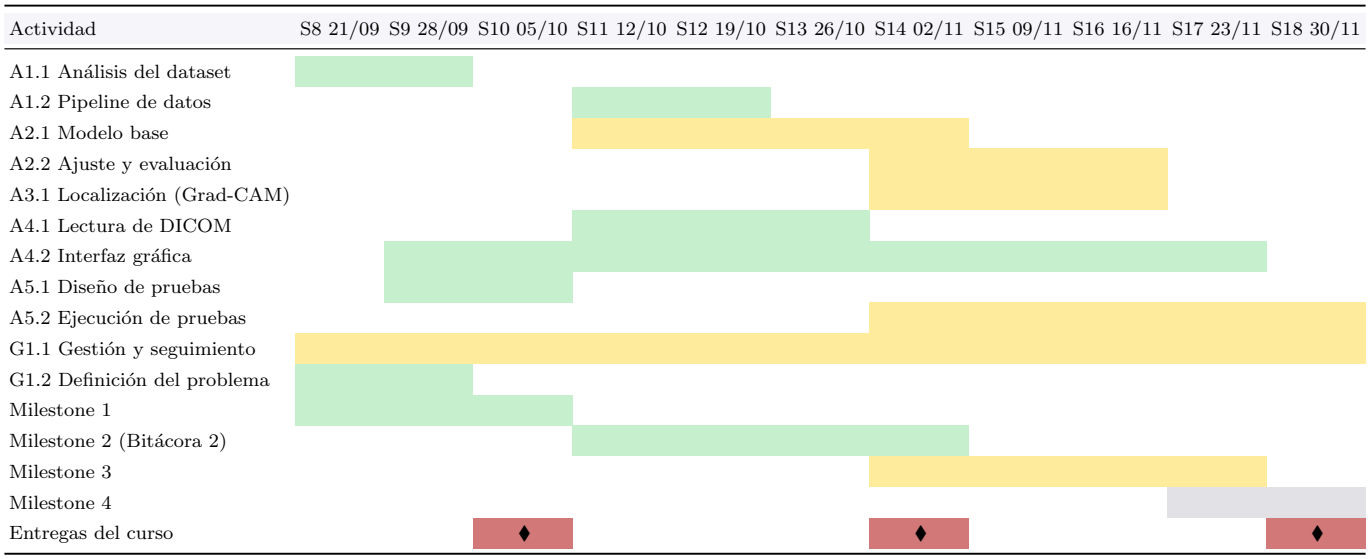
Continúa en la página siguiente...

ID	Tarea	Autor(es)	Entregable	Avance
T2.1.3	Primer entrenamiento y curvas de aprendizaje	Nicolas Severino	Pesos del modelo y gráficos de pérdida	50 %
T2.2.1	Ponderación de clases y ajuste de hiperparámetros	Nicolas Severino	Registro de experimentos	100 %
T2.2.2	Evaluación AUC-ROC por patología en el conjunto de prueba	—	Informe de métricas	0 %
T3.1.1	Implementar Grad-CAM sobre el clasificador	Karime Jarufe	Módulo LOC (código)	100 %
T3.1.2	Conversión de mapas de calor a cajas delimitadoras	Karime Jarufe	Función `to_boxes` y ejemplos visuales	100 %
T3.1.3	Evaluación de IoU con `BBox_List_2017`	Karime Jarufe	Informe de IoU	0 %
T4.1.1	Lector DICOM con validación (DCM)	Benjamin Arias	Módulo DCM (código)	100 %
T4.1.2	Pruebas de consistencia entre DICOM y PNG	Benjamin Arias	Informe de consistencia	100 %
T4.2.1	Diseño de mockups de interfaces (Hito 1)	Karime Jarufe	Prototipos y tabla de eventos	100 %
T4.2.2	Implementar la GUI según los mockups	Karime Jarufe	Aplicación GUI (código)	100 %
T4.2.3	Integrar GUI con DCM, PRE, CLS y LOC	Karime Jarufe, Benjamin Arias	Sistema integrado	100 %
T5.1.1	Diseñar el plan de pruebas	Nicolas Severino	Plan de pruebas (Documento del Hito 1)	100 %
T5.2.1	Ejecutar pruebas unitarias de módulos	Hans Varela	Scripts de prueba y resultados	100 %
T5.2.2	Ejecutar pruebas de sistema y de usabilidad	Todo el equipo	Informe de pruebas	0 %
T5.2.3	Informe final y conclusiones	Todo el equipo	Informe final	0 %
G1.1.1	Documento de Análisis y Diseño v1.0	Todo el equipo	Documento	100 %
G1.1.2	Presentación de Análisis y Diseño	Todo el equipo	Presentación	100 %
G1.1.3	Bitácora 1	Todo el equipo	Planilla de bitácora	100 %
G1.1.4	Reuniones semanales de seguimiento (ciclo scrum)	Todo el equipo	Actas breves de reunión	En curso
G1.1.5	Bitácora 2	Todo el equipo	Planilla de bitácora y avance	100 %
G1.1.6	Presentación y material para la Feria	—	Presentación o póster	0 %
G1.1.7	Bitácora 3	—	Planilla de bitácora e informe final	0 %
G1.2.1	Definir el problema, su alcance y sus límites	Todo el equipo	Documento del Hito 1	100 %

2.5. Carta Gantt

Planificación por semana del calendario del curso, con el color del estado de cada actividad en el corte de la semana 14. = completada; = parcial o asignada; = planificada sin iniciar; ♦ = entrega del curso.

Cuadro 4: Carta Gantt



2.6. Nivel de madurez tecnológica

Usando la escala TRL del material del curso, el equipo estima el prototipo entre **TRL 3** (prueba de concepto de funciones críticas) y **TRL 4** (validación de componentes en laboratorio). La cadena completa funciona con un modelo de prueba. Para sostener TRL 4 falta validar el modelo completo con las pruebas PM2 y PM3.

3. Solución desarrollada

3.1. Scripts del proyecto

La solución se organizó como una secuencia de scripts numerados en `evidencias/codigo/`. Cada uno usa como entrada la salida de los anteriores.

Cuadro 5: Scripts de la solución

Script	Función	Salida principal
`01_verificar_dataset.py`	Cuenta imágenes, pacientes y etiquetas, y los compara con los valores esperados del dataset	Reporte en consola
`02_split_dataset.py`	Divide en entrenamiento, validación y prueba, sin repetir pacientes entre conjuntos	`train.csv`, `val.csv`, `test.csv`
`02-1_analisis_dataset.py`	Calcula estadísticas de clases, hallazgos por imagen y co-ocurrencia	`estadisticas.md` y gráficos
`03_calcular_pesos.py`	Calcula los pesos por clase para compensar el desbalance	`class_weights.json`
`04_crear_subconjunto.py`	Crea un subconjunto de 2.000 imágenes de entrenamiento y 500 de validación para pruebas rápidas	`debug_train.csv`, `debug_val.csv`
`05_entrenar.py`	Entrena el modelo; la opción `--debug` elige el subconjunto y, sin ella, usa el conjunto completo	`modelo_base.keras` y registros por etapa
`06_gui.py`	Aplicación gráfica: lectura DICOM, inferencia, Grad-CAM, cajas y exportación	Archivos en `resultados/`
`11_reporte_test.py`	Ejecuta las pruebas automatizadas y genera su reporte	`tests_sin_modelo.md`

3.2. Preparación de datos

3.2.0.1 Verificación (01).

Compara el total de filas y los conteos de las 14 patologías y de "No Finding" con los valores esperados. Termina con código de error si encuentra diferencias.

3.2.0.2 División por paciente (02).

Usa las listas oficiales `train_val_list.txt` y `test_list.txt`. Dentro de `train_val` separa el 12 % de los pacientes para validación con `GroupShuffleSplit` y semilla 42, y detiene la ejecución si un paciente aparece en más de un conjunto.

3.2.0.3 Pesos por clase (03).

Para cada patología calcula $w = \sqrt{(N-P)/P}$, donde N es el total de imágenes de entrenamiento y P las positivas. La raíz suaviza la diferencia entre clases: la razón entre el peso mayor y el menor baja de 126 a 11 veces.

3.2.0.4 Subconjunto de prueba (04).

Selecciona primero hasta 60 positivos por patología, partiendo por las más raras, y completa con imágenes al azar hasta llegar a 2.000. Permite comprobar el flujo de entrenamiento sin esperar un entrenamiento completo.

3.3. Modelo y entrenamiento

- **Arquitectura:** DenseNet-121 [4] preentrenada en ImageNet, seguida de *Global Average Pooling*, *Dropout* de 0,3 y una capa densa de 14 salidas con activación sigmoide. Tiene 7.051.854 parámetros en total.
- **Preprocesamiento:** imagen en escala de grises redimensionada a 224×224, replicada en 3 canales y normalizada con la función de DenseNet.
- **Aumento de datos:** rotación de ±10°, zoom de ±10 % y variaciones leves de brillo y contraste. No se usa volteo horizontal, porque cambia el lado del corazón.
- **Pérdida:** entropía cruzada binaria con el peso del Cuadro 8 en el término positivo.
- **Etapa 1:** red base congelada, 3 épocas por defecto y tasa de aprendizaje de 10^{-3}.
- **Etapa 2:** ajuste fino de las últimas 60 capas, 10 épocas por defecto y tasa de 10^{-5}. Las capas *BatchNormalization* permanecen congeladas.

- **Control:** guarda el mejor modelo según el AUC de validación, con detención temprana y reducción de la tasa de aprendizaje.

3.4. Localización

Para cada patología, `06_gui.py` aplica Grad-CAM [3] sobre la capa `relu`, la última activación convolucional de la red. El mapa se binariza en 0,5 y se buscan componentes conexas con OpenCV. Se descartan las que ocupan menos del 0,5 % de la imagen y se conservan hasta dos por patología, convertidas en cajas a la escala de la imagen original.

3.5. Ambiente de desarrollo

- **Hardware de entrenamiento:** GPU AMD Radeon RX 9070 XT (16 GB de VRAM) con ROCm.
- **Software:** Linux, Python 3.12.16, TensorFlow 2.21 (compilación propia) con precisión mixta, `pydicom`, OpenCV, Pillow, Pandas, scikit-learn, Gradio y pytest.
- **Dataset:** NIH ChestX-ray14, que no se incluye en el repositorio.

4. Resultados

4.1. Verificación y estadísticas del dataset

El script 01 confirmó las 112.120 imágenes y los 30.805 pacientes, y los 15 conteos coincidieron con los valores esperados. El 53,84 % de las imágenes no tiene hallazgos y el 18,55 % tiene dos o más patologías.

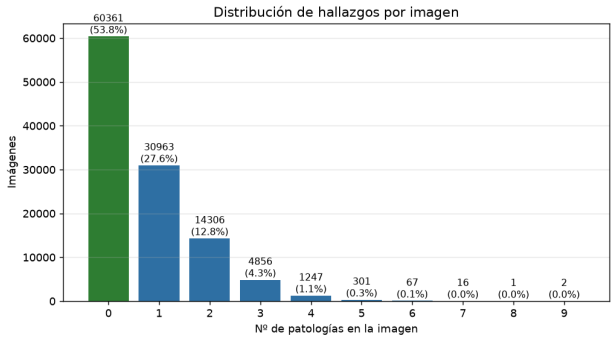


Figura 1: Número de hallazgos por imagen

La co-ocurrencia se midió con el *lift*, es decir, la razón entre la frecuencia conjunta observada y la esperada por azar. Un valor mayor que 1 indica que dos patologías aparecen juntas más de lo esperado.

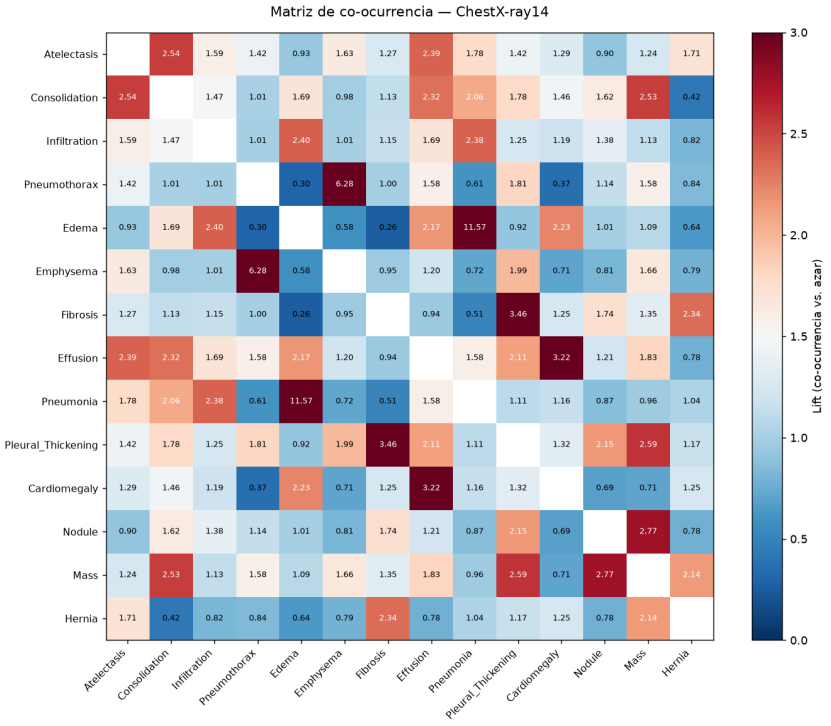


Figura 2: Matriz de co-ocurrencia (lift) entre las 14 patologías

Cuadro 6: Pares de patologías con mayor lift

Par	Casos	Lift	Interpretación del reporte
Edema + Pneumonia	340	11,57	Edema perilesional y complicación aspirativa de la neumonía
Pneumothorax + Emphysema	747	6,28	Rotura de bullas enfisematosas y neumotórax espontáneo
Fibrosis + Pleural_Thickening	176	3,46	Fibrosis subpleural con engrosamiento pleural periférico
Effusion + Cardiomegaly	1.063	3,22	Insuficiencia cardíaca congestiva
Nodule + Mass	906	2,78	Espectro continuo: un nódulo es una masa menor a 3 cm

Estas interpretaciones son hipótesis generadas para el reporte y no han sido validadas por un profesional de la salud. Los pares con clases poco frecuentes deben leerse con cautela.

4.2. División por paciente

Cuadro 7: Resultado de la división del dataset

Conjunto	Imágenes	% imágenes	Pacientes	% pacientes
Entrenamiento	76.277	68,03 %	24.647	80,01 %
Validación	10.247	9,14 %	3.361	10,91 %
Prueba	25.596	22,83 %	2.797	9,08 %
Total	**112.120**	**100 %**	**30.805**	**100 %**

La suma de pacientes por conjunto coincide con el total de pacientes únicos, lo que es consistente con la verificación que hace el script: ningún paciente se repite entre conjuntos.

4.3. Pesos por clase

Cuadro 8: Frecuencia y peso por clase en el conjunto de entrenamiento

Patología	Positivos	Frecuencia	Peso (raíz)
Atelectasis	7.236	9,49 %	3,09
Consolidation	2.542	3,33 %	5,39
Infiltration	12.190	15,98 %	2,29
Pneumothorax	2.337	3,06 %	5,62
Edema	1.234	1,62 %	7,80
Emphysema	1.295	1,70 %	7,61
Fibrosis	1.084	1,42 %	8,33
Effusion	7.638	10,01 %	3,00
Pneumonia	765	1,00 %	9,94
Pleural_Thickening	1.931	2,53 %	6,20
Cardiomegaly	1.509	1,98 %	7,04
Nodule	4.146	5,44 %	4,17
Mass	3.554	4,66 %	4,52
Hernia	115	0,15 %	25,73

4.4. Entrenamiento de prueba

El modelo actual se entrenó con el subconjunto de 2.000 imágenes durante 2 épocas, solo para comprobar que el flujo de entrenamiento funciona.

Cuadro 9: Métricas del entrenamiento de prueba (`log_etapa1.csv`)

Época	AUC entrenamiento	Pérdida entrenamiento	AUC validación	Pérdida validación
1	0,529	0,905	0,565	0,573
2	0,564	0,852	0,611	0,545

Las métricas mejoran entre ambas épocas, lo que indica que el flujo de entrenamiento aprende. Con 2 épocas y un subconjunto, el valor de 0,61 **no es comparable con la literatura** y no sirve para evaluar RNF8. Tampoco se dispone aún de curvas de aprendizaje ni de métricas en el conjunto de prueba.

5. Arquitectura implementada

5.1. Diagrama de arquitectura

Se mantiene el flujo definido en el Hito 1: GUI → DCM → PRE → CLS → LOC → GUI. En desarrollo, TRN usa PRE para entrenar a CLS y entrega los pesos del modelo.

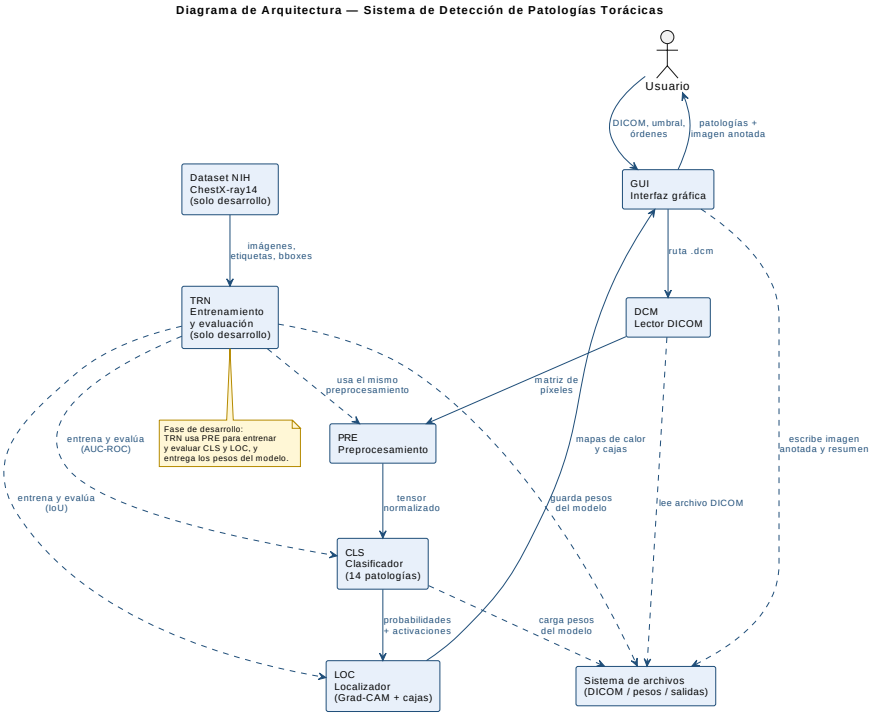


Figura 3: Diagrama de arquitectura del sistema

5.2. Módulos y código

Cuadro 10: Implementación de los módulos

Módulo	Archivo	Funciones principales
Lector DICOM (DCM)	`06_gui.py`	`load_dicom`, `load_png`, `cargar_imagen`
Preprocesamiento (PRE)	`05_entrenar.py`, `06_gui.py`	`to_224_rgb`, `normalize`, `_preprocess_real`
Clasificador (CLS)	`05_entrenar.py`, `06_gui.py`	`build_model`, `predict`
Localizador (LOC)	`06_gui.py`	`heatmap`, `to_boxes`
Interfaz gráfica (GUI)	`06_gui.py`	`construir` y funciones `on_*`
Entrenamiento y evaluación (TRN)	`01` a `05`	Preparación de datos y entrenamiento. La evaluación en prueba está pendiente

5.3. Cambios respecto del diseño del Hito 1

Cuadro 11: Decisiones tomadas durante la implementación

Aspecto	Diseño del Hito 1	Implementación
Framework del modelo	PyTorch o TensorFlow/Keras	TensorFlow/Keras
Interfaz	PyQt, Tkinter, Streamlit o Gradio	Gradio, servida localmente en `127.0.0.1`
Tamaño de entrada	224×224 o 320×320	224×224
Estructura del código	Una clase por módulo	Funciones agrupadas por script
Preprocesamiento	Módulo único	La misma lógica está duplicada en `05_entrenar.py` y `06_gui.py`
Formatos de entrada	DICOM	DICOM y PNG
Exportación	Diálogo de guardado	Carpeta automática `resultados/` con PNG, CSV y JSON, descargables desde la aplicación
Umbral inicial	0,50 en el prototipo	0,30, con rango de 0,05 a 0,95

5.4. Estado de los requisitos

Cuadro 12: Estado de los requisitos en el corte de la semana 14

Requisito	Estado	Observación
RF1 Cargar imagen DICOM	Implementado	También acepta PNG
RF2 Validar archivo	Parcial	Valida que sea DICOM, en escala de grises y 2D. No comprueba que sea una radiografía de tórax
RF3 Visualizar imagen	Implementado	Visor de la pantalla principal
RF4 Preprocesar imagen	Implementado	Aplica escala, ventana, inversión de MONOCHROME1 y redimensionamiento
RF5 Detectar patologías	Implementado	Entrega 14 probabilidades con el modelo de prueba
RF6 Localizar patologías	Parcial	Grad-CAM y cajas funcionan. Falta evaluar su calidad con IoU
RF7 Mostrar resultados	Implementado	Lista, barras, cajas y mapa de calor
RF8 Ajustar umbral	Implementado	Al soltar el control se repite el análisis completo
RF9 Exportar resultados	Implementado	Imagen anotada, CSV y JSON
RF10 Entrenar y evaluar	Parcial	Entrenamiento implementado. Falta el entrenamiento completo y la evaluación en prueba
RNF1 Rendimiento	Sin medir	Depende de la prueba PS1
RNF2 Usabilidad	Parcial	El flujo es cargar, analizar y ver resultados. Falta la prueba con usuarios (PS5)
RNF3 Portabilidad	Parcial	Solo hay evidencia de ejecución en Linux
RNF4 Mantenibilidad	Parcial	Código documentado y versionado, con lógica de preprocesamiento duplicada
RNF5 Privacidad y seguridad	Implementado	Ejecución local. Solo se escriben archivos cuando el usuario exporta
RNF6 Reproducibilidad	Parcial	Hay semillas en división, subconjunto y mezcla, pero no una semilla global para el entrenamiento
RNF7 Transparencia	Parcial	El aviso está en la barra de estado, pero en la grabación queda bajo el borde visible de la ventana
RNF8 Desempeño del modelo	Pendiente	Requiere el entrenamiento completo y PM2

6. Interfaz implementada

La aplicación sigue la distribución del Prototipo 1 del Hito 1: visor a la izquierda, panel de resultados a la derecha y controles en la parte inferior. Las figuras son cuadros del video de demostración, grabado el 5 de noviembre de 2026 con el modelo de prueba. Sus valores solo ilustran el funcionamiento y no tienen validez clínica.

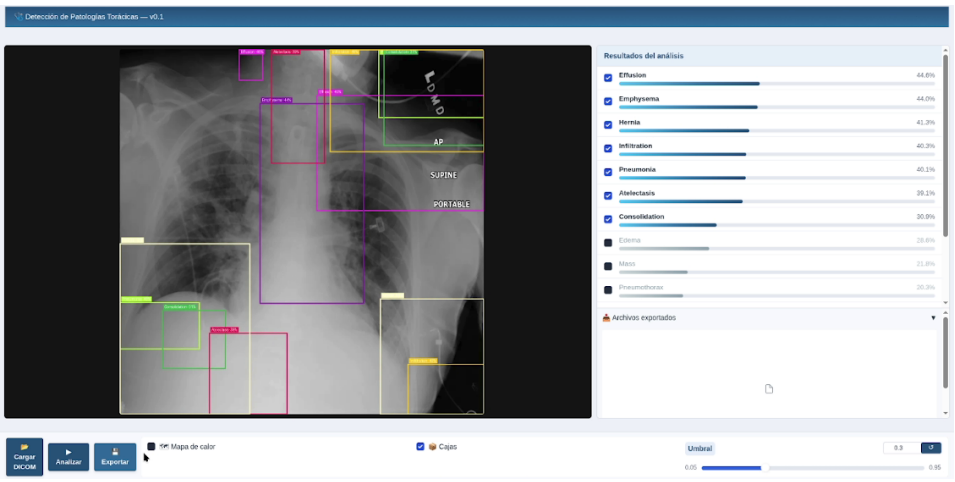


Figura 4: Resultado del análisis con cajas y umbral 0,30

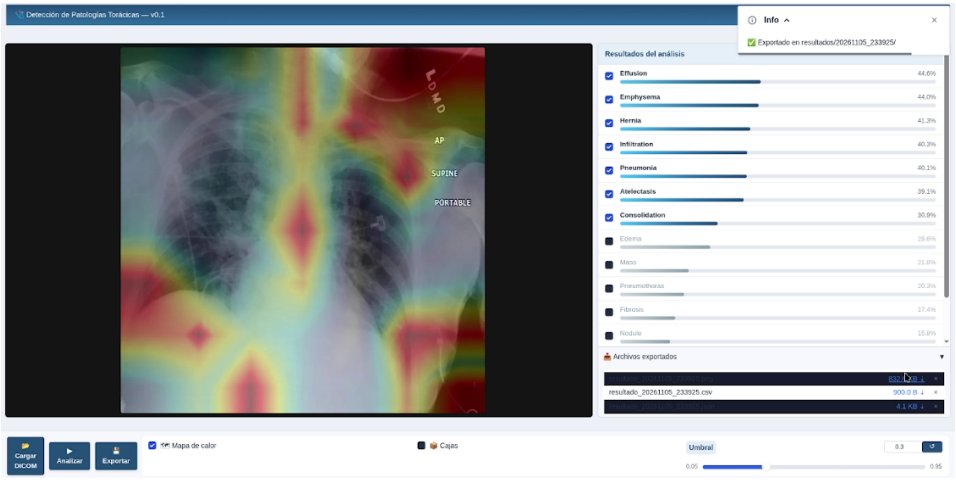


Figura 5: Mapa de calor de Grad-CAM y archivos exportados



Figura 6: Selección de patologías, cambio de umbral y rechazo de un archivo no permitido

	Patologia	Probabilidad	Sobre_umbral	Mostrada	N_cajas	Cajas_xywh
2	Atelectasis	0.390869	True	True	2	(425,0,151,320);(251,795,220,229)
3	Consolidation	0.308594	True	True	2	(741,0,283,270);(119,731,178,165)
4	Infiltration	0.402588	True	True	2	(590,0,434,288);(809,882,215,142)
5	Pneumothorax	0.203491	False	False	1	(398,128,187,311)
6	Edema	0.285889	False	False	1	(0,667,146,247)
7	Emphysema	0.439941	True	True	1	(393,151,293,562)
8	Fibrosis	0.174438	False	False	1	(0,0,146,146)
9	Effusion	0.446289	True	True	2	(553,128,471,325);(334,0,68,87)
10	Pneumonia	0.400879	True	True	2	(727,0,297,192);(0,709,224,132)
11	Pleural Thickening	0.139282	False	False	1	(439,0,228,146)
12	Cardiomegaly	0.141724	False	False	2	(73,905,370,119);(553,832,274,192)
13	Nodule	0.158447	False	False	1	(293,576,283,448)
14	Mass	0.217896	False	False	1	(439,731,146,211)
15	Hernia	0.412842	True	True	2	(0,544,366,480);(731,699,293,325)

Figura 7: Resumen exportado en CSV

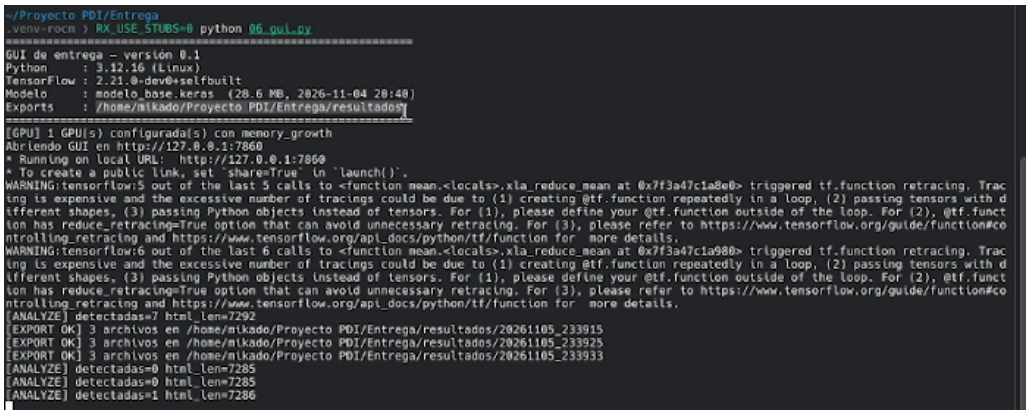


Figura 8: Consola de la demostración: modelo real (`RX_USE_STUBS=0`)

Cuadro 13: Interacciones implementadas

Evento	Acción	Objeto afectado
Cargar DICOM	Carga y valida el archivo. Si es válido, muestra la imagen	Visor, barra de estado
Analizar	Ejecuta el modelo y Grad-CAM para las 14 patologías	Visor, panel de resultados
Cambiar umbral	Repite el análisis y marca las patologías sobre el umbral	Visor, panel de resultados
Marcar patología	Muestra u oculta su región	Visor
Mapa de calor / Cajas	Activa o desactiva cada capa sobre la imagen	Visor
Exportar	Guarda imagen anotada, CSV y JSON y permite descargarlos	Archivos exportados
Archivo inválido	Muestra un mensaje de error emergente y no ejecuta el análisis	Notificación

Observación de la demostración. Las probabilidades son parecidas entre sí y varias regiones caen sobre marcadores de la placa o fuera del pulmón. Esto es esperable en un modelo de prueba y confirma que la localización todavía no puede considerarse confiable. Su calidad se medirá con la prueba PM3 sobre el modelo completo.

7. Pruebas

7.1. Pruebas automatizadas

El reporte generado el 6 de noviembre de 2026 registra **26 pruebas aprobadas de 26**, sin fallas, en 24,12 segundos. La ejecución excluye por diseño la prueba `test_pu5_heatmap_forma`, marcada como dependiente del modelo. Las pruebas usan principalmente datos sintéticos, y las de CLS verifican la arquitectura sin pesos entrenados.

Cuadro 14: Resultado de las pruebas automatizadas por archivo

Archivo	Total	Aprobadas	Qué verifica
`test_dcm`	6	6	Lectura de DICOM, inversión, ventana, percentiles y rechazo de archivos inválidos
`test_loc`	3	3	Cajas dentro de los límites, mapa vacío y escala
`test_model`	3	3	Salida de 14 valores entre 0 y 1, capa de Grad-CAM y compilación
`test_pre`	3	3	Forma, tipo y normalización de la imagen
`test_split`	4	4	Sin pacientes repetidos, orden de columnas y proporción de validación
`test_subset`	2	2	Subconjunto con todas las clases y positivos mínimos
`test_verify`	2	2	Conteos y codificación multi-etiqueta
`test_weights`	3	3	Catorce pesos positivos, con Hernia como el mayor
Total	**26**	**26**	

7.2. Estado del plan de pruebas

Cuadro 15: Avance del plan de pruebas del Hito 1

ID	Prueba	Estado	Evidencia u observación
PM1	Sin pacientes repetidos entre conjuntos	Aprobada	Verificación en `02_split_dataset.py`, `test_split` y log de división
PM2	AUC-ROC por patología en prueba	Pendiente	Requiere el entrenamiento completo
PM3	IoU contra cajas reales	Pendiente	Requiere el modelo completo y un script de evaluación
PM4	Reproducibilidad con la misma semilla	Pendiente	Falta fijar una semilla global de entrenamiento
PU1	DCM lee un DICOM válido	Aprobada	`test_dcm`, con DICOM sintéticos
PU2	DCM rechaza un archivo no DICOM	Aprobada	`test_dcm`
PU3	PRE equivalente para PNG y DICOM	Parcial	`test_pre` y comparación con una imagen sintética de 8 bits. Falta comparar el flujo completo y DICOM de 12–16 bits
PU4	CLS entrega 14 valores entre 0 y 1	Aprobada	`test_model`, sin pesos entrenados
PU5	LOC entrega cajas dentro de la imagen	Aprobada	`test_loc`
PS1	Flujo completo en menos de 10 s	Parcial	Flujo demostrado en video. Falta medir el tiempo
PS2	Cambiar el umbral	Parcial	Demostrado en video. Falta la prueba formal
PS3	Exportar resultados	Parcial	Demostrado en video. Falta la prueba formal
PS4	Cargar un archivo inválido	Parcial	Demostrado en video con un archivo HTML. Faltan otros casos, como un DICOM dañado
PS5	Usabilidad con usuarios objetivo	Pendiente	Planificada para la semana 17

8. Seguimiento y próximos pasos

8.1. Tareas del siguiente ciclo (semana 15)

- **Nicolas:** ejecutar el entrenamiento completo con 76.277 imágenes (3 + 10 épocas) y preparar las curvas de aprendizaje y la evaluación AUC-ROC.
- **Karime:** evaluar el IoU con `BBox_List_2017`.
- **Benjamin:** refinar la GUI.
- **Todo el equipo:** incorporar los comentarios del profesor sobre el documento del Hito 1 y mantener las reuniones semanales.

8.2. Impedimentos y riesgos

Cuadro 16: Impedimentos y riesgos

Impedimento o riesgo	Acción
El entrenamiento completo requiere de 6 a 8 horas de GPU dedicada	Ejecutarlo en la semana 15, según lo asignado en la Bitácora 2
Las evaluaciones de AUC e IoU dependen del modelo completo	Priorizar el entrenamiento antes de esas tareas
Congelamientos del sistema operativo bajo carga de GPU	Crecimiento gradual de VRAM y concurrencia limitada en la GUI
El método de localización podría ser insuficiente	Decidir con los resultados de IoU si Grad-CAM basta o se requiere un detector
Solo 8 de las 14 patologías tienen cajas reales	Informar el IoU solo para esas 8 patologías

8.3. Próximos hitos

- **Milestone 3**, sistema integrado: semana 17 (del 23/11 al 27/11).
- **Milestone 4**, Feria y Bitácora 3: semana 18 (del 30/11 al 04/12).

9. Conclusiones

El Hito 2 convierte el diseño del Hito 1 en una cadena funcional: desde la verificación y división del dataset hasta una aplicación que lee DICOM, ejecuta el modelo, marca regiones y exporta resultados. Se comprobó la división sin pacientes repetidos, y las 26 pruebas automatizadas ejecutadas fueron aprobadas.

El principal pendiente es el desempeño. El modelo disponible es de prueba, por lo que todavía no se puede afirmar nada sobre la calidad de la clasificación ni de la localización. El siguiente ciclo se concentra en el entrenamiento completo y en las evaluaciones AUC-ROC e IoU, que permitirán fijar la meta de desempeño y decidir si Grad-CAM es suficiente.

10. Referencias

1. X. Wang, Y. Peng, L. Lu, Z. Lu, M. Bagheri y R. M. Summers, "ChestX-ray8: Hospital-scale chest X-ray database and benchmarks on weakly-supervised classification and localization of common thorax diseases," en *Proc. IEEE CVPR*, 2017, pp. 3462–3471. (arXiv:1705.02315)
2. P. Rajpurkar et al., "CheXNet: Radiologist-level pneumonia detection on chest X-rays with deep learning," arXiv:1711.05225, 2017.
3. R. R. Selvaraju et al., "Grad-CAM: Visual explanations from deep networks via gradient-based localization," en *Proc. IEEE ICCV*, 2017.
4. G. Huang, Z. Liu, L. van der Maaten y K. Q. Weinberger, "Densely connected convolutional networks," en *Proc. IEEE CVPR*, 2017.
5. M. Zúñiga, "Elementos Iniciales de Planificación de Proyectos," material del curso, Departamento de Electrónica, Universidad Técnica Federico Santa María, septiembre de 2026.

A. Guía de ejecución

Los comandos se ejecutan desde la carpeta del código. Se necesita el dataset NIH ChestX-ray14 y, para la aplicación, el archivo `models/modelo_base.keras`, que no forma parte de las evidencias.

```
python 01_verificar_dataset.py --entry-csv /ruta/Data_Entry_2017.csv
python 02_split_dataset.py --dataset-dir /ruta/dataset
python 02-1_analisis_dataset.py --splits-dir data/splits --out-dir reportes
python 03_calcular_pesos.py --splits-dir data/splits
python 04_crear_subconjunto.py --splits-dir data/splits

# Entrenamiento de prueba
python 05_entrenar.py --images-dir /ruta/images --debug --epochs-head 3 --epochs-ft 0
# Entrenamiento completo
python 05_entrenar.py --images-dir /ruta/images --epochs-head 3 --epochs-ft 10

python 06_gui.py                # Aplicacion con el modelo entrenado
RX_USE_STUBS=1 python 06_gui.py # Aplicacion con datos simulados, sin modelo
python 11_reporte_test.py       # Pruebas y reporte
```

B. Índice de evidencias

Cuadro 17: Evidencias del Hito 2 en la carpeta `evidencias/`

Ubicación	Contenido
`codigo/`	Scripts del Cuadro 5 y `pytest.ini`
`codigo/tests/`	Pruebas automatizadas
`logs/`	Salidas de verificación, división, entorno, pesos, consistencia, pruebas y entrenamiento
`capturas/`	Capturas de pantalla de cada tarea, identificadas con su ID
`reportes/`	Estadísticas, matrices de co-ocurrencia, gráficos y reporte de pruebas
`datos/`	Primeras filas de cada conjunto y `class_weights.json`
`video/`	Demostración de la GUI (`Gui.mp4` y `Gui(1).mp4`)
`Copia de Bitacora_2_...xlsx`	Bitácora 2: tareas, Carta Gantt, seguimiento y calendario