UNIVERSIDAD TECNICA
FEDERICO SANTA MARIA

DEPARTAMENTO DE
ELECTRONICA

Detección y localización de patologías torácicas en radiografías mediante Deep Learning

Documento de Análisis, Planificación y Diseño — Hito 2

Fecha 6 de noviembre de 2026
Integrantes: Benjamin Esteban Arias Vega
Karime Andrea Jarufe Escobar
Nicolas Eduardo Severino Palma
Hans David Varela Antilao
Asignatura: TEL328
Profesor: Marcos Zúñiga
Versión: 2.0 (Hito 2 – Avance de la solución)

Índice

1 Introducción **4**
1.1 Objetivos . . . 4

2 Diagnóstico e identificación del problema, desafío u oportunidad **4**

3 Propuesta de solución **5**

4 Estado del Arte y de la Técnica **5**
4.1 Investigación y datasets . . . 5
4.2 Soluciones comerciales . . . 6
4.3 Patentes . . . 6
4.4 Técnicas utilizadas . . . 6

5 Requisitos del Sistema **7**
5.1 Requisitos Funcionales . . . 7
5.2 Requisitos no funcionales . . . 7
5.3 Requisitos de Interfaces . . . 8

6 Requisitos de Ambiente **8**
6.1 Hardware de Desarrollo . . . 8
6.2 Software de Desarrollo . . . 8
6.3 Datasets e Imágenes/Videos de Prueba . . . 8
6.4 Perfiles de Usuario . . . 10

7 Planificación del Proyecto **11**
7.1 Objetivo General (Goal) . . . 11
7.2 Objetivos Específicos . . . 11
7.3 Actividades y Milestones . . . 11
7.4 Carta Gantt . . . 12

8 Diseño de Arquitectura del Sistema **13**
8.1 Diagrama de Contexto . . . 13
8.2 Diagrama de Arquitectura . . . 13
8.3 Enumeración de Módulos . . . 14
8.4 Matriz de Requisitos Funcionales y Módulos . . . 15
8.5 Definición de Módulos . . . 15
8.5.1 Módulo DCM – Lector DICOM (`06_gui.py`) . . . 15
8.5.2 Módulo PRE – Preprocesamiento (`05_entrenar.py`) . . . 15
8.5.3 Módulo CLS – Clasificador (`05_entrenar.py`) . . . 15
8.5.4 Módulo LOC – Localizador (`06_gui.py`) . . . 16
8.5.5 Módulo GUI – Interfaz gráfica (`06_gui.py`) . . . 16
8.5.6 Módulo TRN – Entrenamiento y evaluación (scripts `01` a `05`) . . . 16

9 Diseño de Interfaces **17**
9.1 Modelo de Navegación . . . 17
9.2 Prototipos de Interfaces Usuarias . . . 17

9.2.1 Prototipo 1 – Pantalla Principal 17
9.2.2 Prototipo 2 – Mensaje de error 18
9.3 Interfaz implementada (Hito 2) 18
9.4 Ejemplo de localización sobre la imagen 19

10 Diseño de Pruebas **21**

11 Avance de la Solución **23**
11.1 Datos (O1) 23
11.2 Modelo base (O2) 23
11.3 Localización (O3) 24
11.4 Lectura DICOM (O4) 24
11.5 Interfaz e integración (O4) 24
11.6 Pruebas (O5) 24
11.7 Riesgos y próximos pasos 25

12 Conclusiones **25**

13 Referencias **25**

Índice de figuras

1 Diagrama de contexto. 13
2 Diagrama de arquitectura del sistema. 14
3 Diagrama de modelo de navegación. 17
4 Prototipo 1 – Pantalla Principal (mockup del Hito 1). 18
5 Prototipo 2 – Mensaje de error. 18
6 Interfaz implementada: resultados con umbral 0,30, mapa de calor Grad-CAM y cajas por patología. 19
7 Ejemplo de localización: Effusion seleccionada con umbral 0,44; mapa de calor Grad-CAM y región sobre la radiografía. 20
8 Número de hallazgos por imagen en NIH ChestX-ray14: el 53,84 % no tiene hallazgos y el 18,55 % tiene dos o más. 23
9 Ejecución de las pruebas unitarias: 26 de 26 aprobadas. 25

Índice de cuadros

1 Soluciones comerciales de IA para radiografía de tórax 6
2 Eventos externos 8
3 Respuestas del sistema 8
4 Distribución de diagnósticos y cajas delimitadoras (112.120 imágenes) 9
5 División del dataset por paciente 9
6 Perfiles de usuario 10
7 Actividades y milestones (estado a la semana 14) 11
8 Carta Gantt (estado a la semana 14) 12
9 Módulos de la arquitectura del sistema 14
10 Matriz de requisitos funcionales y módulos 15
11 Interacciones de la pantalla principal 18
12 Pruebas del modelo 21
13 Pruebas unitarias de módulos 21
14 Pruebas de sistema e interfaz 22
15 Pesos por clase en el conjunto de entrenamiento (76.277 imágenes) 23
16 Prueba de funcionamiento del entrenamiento (subconjunto, solo cabeza) 24

1 Introducción

La radiografía de tórax es uno de los exámenes de imagenología más frecuentes y de menor costo en la práctica clínica. Sin embargo, su interpretación es compleja: varias patologías pulmonares se ven parecidas entre sí (por ejemplo, infiltrado, consolidación y neumonía), y su diagnóstico visual depende de la experiencia del especialista. Esto hace de la radiografía de tórax un caso atractivo para sistemas de apoyo al diagnóstico basados en inteligencia artificial.

Este proyecto desarrolla un sistema que recibe una radiografía de tórax en formato DICOM, la procesa con un modelo de Deep Learning y entrega al usuario (i) las patologías probables presentes en la imagen y (ii) su ubicación aproximada sobre la radiografía. El modelo se entrena con el dataset público NIH ChestX-ray14 [1], que contiene 112.120 radiografías frontales de 30.805 pacientes, con etiquetas para 14 categorías de patologías torácicas.

El sistema se concibe como una herramienta de apoyo y prototipo académico, **no como un dispositivo de diagnóstico**: cualquier resultado debe ser revisado por un profesional de la salud.

Este documento corresponde al Hito 2. Mantiene el análisis y diseño del Hito 1, con las correcciones listadas en el Cuadro **??**, y agrega el estado real de la planificación (sección 7) y el avance de la solución (sección 11).

1.1 Objetivos

1. **O1.** Analizar y preparar el dataset NIH ChestX-ray14, respetando la división por paciente, para disponer de conjuntos de entrenamiento, validación y prueba reproducibles.
2. **O2.** Entrenar un modelo de clasificación multietiqueta de 14 patologías y evaluarlo con AUC-ROC por patología sobre el conjunto de prueba.
3. **O3.** Implementar un método de localización de las regiones afectadas y evaluarlo con las cajas delimitadoras disponibles (IoU).
4. **O4.** Desarrollar una aplicación con interfaz gráfica que reciba una imagen DICOM, ejecute el modelo y muestre patologías y ubicación.
5. **O5.** Diseñar y ejecutar un plan de pruebas que verifique los requisitos funcionales y no funcionales del sistema.

2 Diagnóstico e identificación del problema, desafío u oportunidad

Problema. El diagnóstico de patologías pulmonares a partir de radiografías de tórax es difícil y variable. Los síntomas clínicos suelen ser inespecíficos (por ejemplo, la neumonía puede confundirse con un resfrío o una gripe), por lo que el médico integra antecedentes, examen físico y estudios de imagen. Dentro de ese proceso, la radiografía aporta evidencia visual directa de la afectación pulmonar, pero su lectura es exigente y puede variar entre observadores. Además, un mismo paciente puede presentar varias patologías a la vez: el 18,55 % de las imágenes del dataset tiene dos o más hallazgos, lo que complica aún más la interpretación.

Desafío. Construir un modelo que no solo clasifique, sino que también localice la región afectada, con la limitación de que el dataset dispone de etiquetas por imagen y de solo 984 cajas delimitadoras (*bounding boxes*). Además, las etiquetas fueron extraídas de informes radiológicos mediante procesamiento de lenguaje natural (NLP), con una exactitud estimada superior al 90 % [1], por lo que contienen algo de ruido. Otros desafíos son el desbalance entre clases (Infiltration aparece en 19.894 imágenes (17,74 %) frente a 227 de Hernia (0,20 %), y el 53,84 % de las imágenes no tiene hallazgos) y la diferencia entre el formato de entrenamiento (PNG de 8 bits, 1024×1024) y el formato de uso real (DICOM de 12–16 bits).

Oportunidad. NIH ChestX-ray14 es uno de los mayores conjuntos públicos de radiografías de tórax, con cerca de 27 veces más imágenes frontales que el dataset previo Open-i [1]. Esto permite entrenar redes profundas con volúmenes de datos adecuados y disponer de una división oficial por paciente. Con ello es viable desarrollar un prototipo completo, desde el entrenamiento hasta una interfaz que acepte DICOM, y evaluar su desempeño con métricas estándar.

3 Propuesta de solución

El qué. Un sistema compuesto por (a) un modelo de Deep Learning multietiqueta que estima la probabilidad de cada una de las 14 patologías y (b) una aplicación con interfaz gráfica donde el usuario carga una radiografía DICOM, la visualiza y obtiene las patologías detectadas junto con su ubicación marcada sobre la imagen.

El cómo (decisiones de diseño ya implementadas):

1. **Preparación de datos:** uso de `Data_Entry_2017.csv`, `train_val_list.txt` y `test_list.txt`. El conjunto de validación se separa del de entrenamiento *por paciente* (`GroupShuffleSplit`, 12 %, semilla 42), sin pacientes compartidos entre conjuntos.
2. **Modelo de clasificación:** DenseNet-121 [4] preentrenada en ImageNet, con capa de *global average pooling*, *dropout* 0,3 y salida de 14 neuronas sigmoide, como en CheXNet [2]. La pérdida es entropía cruzada binaria ponderada por clase, con peso $\sqrt{N_{neg}/N_{pos}}$ para atenuar el desbalance sin sobrecorregirlo. El entrenamiento es en dos etapas: primero solo la cabeza (backbone congelado) y luego ajuste fino de las últimas capas.
3. **Localización:** Grad-CAM [3] sobre la última activación convolucional (capa `relu`); el mapa se binariza y se convierte en cajas mediante componentes conexas (OpenCV). Las 984 cajas reales se usarán para evaluar la localización con IoU.
4. **Aplicación:** interfaz web local con Gradio que lee DICOM con pydicom, aplica el mismo preprocesamiento que en el entrenamiento, ejecuta la inferencia y muestra probabilidades, mapa de calor y cajas.

Alcance del Hito 2. Pipeline de datos completo, modelo base implementado y probado en un subconjunto, localización con Grad-CAM, lector DICOM, interfaz integrada y pruebas unitarias. Quedan para el Hito 3 el entrenamiento completo, la evaluación AUC-ROC sobre el conjunto de prueba, la evaluación IoU y las pruebas de sistema y usabilidad.

Límites del problema. El grupo definió en conjunto hasta dónde llega el proyecto:

- **Datos:** el modelo se entrena solo con NIH ChestX-ray14, con radiografías frontales. Las etiquetas vienen de informes mediante NLP, y las cajas delimitadoras son pocas (984) y cubren 8 de las 14 patologías.
- **Clínico:** el sistema analiza solo la imagen. No usa antecedentes, síntomas ni examen físico del paciente, y no reemplaza al profesional de la salud.
- **Técnico:** la localización es aproximada, porque se estima con mapas de activación y no con un detector entrenado para todas las patologías. Se espera menor desempeño en las clases poco frecuentes, como Hernia.
- **Validación:** los resultados se miden sobre el conjunto de prueba del propio dataset. No se valida con radiólogos ni con datos de otros hospitales.
- **Fuera de alcance:** uso clínico real, manejo de datos de pacientes reales y certificación médica.

4 Estado del Arte y de la Técnica

4.1 Investigación y datasets

Datasets. ChestX-ray8/14 [1] es el conjunto de referencia por su tamaño, aunque sus etiquetas provienen de NLP y tiene pocas cajas delimitadoras. Challenges como el de detección de neumonía de la RSNA (2018) aportaron anotaciones de localización para una sola patología.

Clasificación. Wang et al. [1] establecieron los primeros resultados de referencia sobre las 14 patologías. CheXNet [2] usó una DenseNet-121 [4] para detectar neumonía y luego las 14 patologías, y es hoy una línea base habitual.

Localización. Dado que hay pocas cajas anotadas, la localización suele hacerse de forma débilmente supervisada con mapas de activación (CAM, Grad-CAM [3]). Con más anotaciones se pueden usar detectores como Faster R-CNN [5] o YOLO. Para pasar de un mapa de calor a regiones se usan técnicas clásicas de segmentación: umbralización y análisis de componentes conexas o contornos.

Formato DICOM. El estándar DICOM [6] almacena la imagen junto con metadatos clínicos, y puede incluir interpretaciones fotométricas (MONOCHROME1/2), parámetros de reescalado (*RescaleSlope/Intercept*) y de ventana (*WindowCenter/Width*) que deben aplicarse antes de la inferencia.

4.2 Soluciones comerciales

Existen productos comerciales de IA para radiografía de tórax con aprobación regulatoria (FDA en Estados Unidos, marcado CE en Europa). El Cuadro 1 resume los más representativos.

Cuadro 1: Soluciones comerciales de IA para radiografía de tórax

Producto (empresa, país)	Regulación	Qué hace
Lunit INSIGHT CXR Triage (Lunit, Corea del Sur) [8]	FDA 510(k), 2021	Triaje: prioriza estudios con hallazgos urgentes (derrame pleural y neumotórax) y avisa al médico.
qXR / qXR-Detect (Qure.ai, India) [9]	FDA 510(k), varias indicaciones (la última en 2026); CE	Detección asistida de hallazgos en pulmón, pleura, hilios, corazón, mediastino y hueso; indica la ubicación con cajas delimitadoras y regiones de interés.
Annalise Enterprise CXR (Annalise.ai, Australia) [10]	FDA 510(k) para triaje; CE clase IIb	Detecta hasta 124 hallazgos en radiografía de tórax en menos de 20 segundos.
ChestEye y ChestLink (Oxipit, Lituania; adquirida por Sectra en 2026) [11]	CE clase IIb	ChestEye genera un informe preliminar con 75 hallazgos; ChestLink informa de forma autónoma las radiografías normales sin intervención del radiólogo.

Diferencias con este proyecto. Los productos comerciales se entrenan con cientos de miles de imágenes etiquetadas por radiólogos (Lunit reporta más de 160.000 radiografías con confirmación por tomografía [8]), pasan por validación clínica y se integran al sistema PACS del hospital. Este proyecto es un prototipo académico: usa un dataset público con etiquetas extraídas por NLP, no tiene validación clínica y funciona como aplicación local. Su aporte es mostrar, de forma reproducible, el flujo completo desde el DICOM hasta la localización, y estudiar qué tan bien localiza un modelo entrenado solo con etiquetas por imagen.

4.3 Patentes

- **US 10,733,727 B2** – *Application of deep learning for medical imaging evaluation* (Qure.ai) [12]: sistema que extrae hallazgos de los informes radiológicos con NLP, los usa como etiquetas para entrenar una red convolucional y detecta y localiza anomalías en radiografías de tórax, con aplicación al tamizaje de tuberculosis. Es el mismo principio con el que se etiquetó NIH ChestX-ray14 y que usa este proyecto.
- **US 10,755,413 B1** – *Method and system for medical imaging evaluation* (Qure.ai) [13]: detección y localización de anomalías en radiografías de tórax mediante segmentación anatómica, generación de regiones de interés y una red híbrida de clasificación y segmentación que entrega mapas de probabilidad por región.

Este proyecto no busca proteger ni comercializar una invención. No se realizó un análisis de libertad de operación, ya que el uso es exclusivamente docente; las técnicas empleadas (DenseNet, Grad-CAM) provienen de la literatura abierta.

4.4 Técnicas utilizadas

Transferencia de aprendizaje, aumento de datos moderado sin volteo horizontal (el volteo cambia el lado del corazón), pérdida ponderada para el desbalance de clases, métricas AUC-ROC por patología e IoU para localización.

5 Requisitos del Sistema

5.1 Requisitos Funcionales

- **RF1 – Cargar imagen DICOM:** el usuario puede seleccionar un archivo DICOM (.dcm) desde su equipo.
- **RF2 – Validar archivo:** el sistema verifica que el archivo sea un DICOM válido en escala de grises y avisa si no lo es.
- **RF3 – Visualizar imagen:** el sistema muestra la radiografía cargada.
- **RF4 – Preprocesar imagen:** el sistema convierte la imagen DICOM al formato de entrada del modelo (escala de intensidad, tamaño y normalización).
- **RF5 – Detectar patologías:** el sistema estima la probabilidad de cada una de las 14 patologías del dataset.
- **RF6 – Localizar patologías:** el sistema indica sobre la imagen la región asociada a cada patología detectada.
- **RF7 – Mostrar resultados:** el sistema lista las patologías sobre un umbral, con su probabilidad, y superpone las regiones sobre la imagen.
- **RF8 – Ajustar umbral:** el usuario puede cambiar el umbral de decisión para mostrar más o menos patologías.
- **RF9 – Exportar resultados:** el usuario puede guardar la imagen anotada y un resumen de resultados.
- **RF10 – Entrenar y evaluar el modelo:** el equipo puede entrenar el modelo y obtener métricas sobre el conjunto de prueba (módulo de desarrollo, no visible al usuario final).

5.2 Requisitos no funcionales

- **RNF1 – Rendimiento:** la inferencia sobre una imagen debe tardar menos de 10 segundos en el equipo objetivo.
- **RNF2 – Usabilidad:** un usuario sin conocimientos técnicos debe poder obtener un resultado en no más de 3 pasos.
- **RNF3 – Portabilidad:** la aplicación debe ejecutarse en Windows y Linux con Python. El entrenamiento usa GPU, pero la aplicación debe poder correr en CPU.
- **RNF4 – Mantenibilidad:** el código debe ser modular, documentado y versionado.
- **RNF5 – Privacidad y seguridad:** las imágenes se procesan localmente y no se envían a servicios externos; no se almacenan datos de pacientes sin acción del usuario.
- **RNF6 – Reproducibilidad:** el entrenamiento debe poder repetirse fijando semillas y registrando la configuración.
- **RNF7 – Transparencia:** la interfaz debe indicar que el resultado es un apoyo y no un diagnóstico médico.
- **RNF8 – Desempeño del modelo:** AUC-ROC promedio sobre las 14 patologías cercano a lo reportado en la literatura para este dataset [1][2]; la meta definitiva se fijará tras el entrenamiento completo.

5.3 Requisitos de Interfaces

Cuadro 2: Eventos externos

Evento	Descripción	Iniciador	Parámetros	Respuesta
Cargar DICOM	El usuario selecciona un archivo .dcm	Usuario	Ruta del archivo	R1
Analizar imagen	El usuario solicita ejecutar el modelo	Usuario	Imagen cargada, umbral	R2
Cambiar umbral	El usuario modifica el umbral de decisión	Usuario	Valor del umbral (0–1)	R3
Exportar	El usuario guarda los resultados	Usuario	Ruta de destino	R4
Archivo inválido	El archivo no es un DICOM válido	Sistema de archivos	Archivo	R5

Cuadro 3: Respuestas del sistema

Respuesta	Descripción	Parámetros
R1	Muestra la imagen cargada y habilita el botón de análisis	Imagen, metadatos básicos
R2	Muestra el listado de patologías con probabilidad y la imagen con regiones superpuestas	Probabilidades, regiones
R3	Actualiza el listado y las regiones mostradas según el nuevo umbral	Umbral
R4	Guarda la imagen anotada y el resumen de resultados (PNG, CSV y JSON)	Archivos de salida
R5	Muestra un mensaje de error y no ejecuta el análisis	Mensaje de error

La interfaz de entrada respeta el estándar DICOM [6].

6 Requisitos de Ambiente

6.1 Hardware de Desarrollo

- Computadores personales de los integrantes para desarrollo de código y de la aplicación.
- **Equipo de entrenamiento (decidido):** PC local de un integrante con GPU AMD Radeon RX 9070 XT de 16 GB de VRAM, usando ROCm, con el dataset completo almacenado localmente.
- Almacenamiento local para el dataset (112.120 imágenes PNG de 1024×1024).

6.2 Software de Desarrollo

- Python 3.12 y **TensorFlow 2.21 / Keras** compilado para ROCm
- pydicom para lectura de DICOM; OpenCV y Pillow para procesamiento de imágenes.
- Pandas y scikit-learn para manejo de metadatos y división por paciente.
- **Gradio** para la interfaz gráfica: se ejecuta como aplicación web local (`127.0.0.1`), por lo que las imágenes no salen del equipo (RNF5) y se puede ejecutar en Windows, Linux y macOS (RNF3).
- pytest para las pruebas unitarias.
- Repositorio de GitHub para codigo, registros y evidencias.

6.3 Datasets e Imágenes/Videos de Prueba

NIH ChestX-ray14 [1]:

- 112.120 imágenes frontales PNG de 1024×1024 de 30.805 pacientes, con 14 etiquetas de patologías (multietiqueta).
- `Data_Entry_2017.csv`: índice de imagen, etiquetas, seguimiento, ID de paciente, edad, sexo, posición de la vista y tamaño y espaciado de píxel originales.
- `BBox_List_2017.csv`: 984 cajas delimitadoras (x, y, w, h).
- `train_val_list.txt` y `test_list.txt`: división oficial por paciente.

Verificación. Se comprobó que los conteos del CSV local coinciden exactamente con los del dataset publicado: 112.120 imágenes, 30.805 pacientes y las 15 categorías (14 patologías y *No Finding*).

Cuadro 4: Distribución de diagnósticos y cajas delimitadoras (112.120 imágenes)

Diagnóstico	Imágenes	% del total	Cajas delimitadoras
No Finding (sin hallazgos)	60.361	53,84 %	—
Infiltration	19.894	17,74 %	123
Effusion	13.317	11,88 %	153
Atelectasis	11.559	10,31 %	180
Nodule	6.331	5,65 %	79
Mass	5.782	5,16 %	85
Pneumothorax	5.302	4,73 %	98
Consolidation	4.667	4,16 %	—
Pleural Thickening	3.385	3,02 %	—
Cardiomegaly	2.776	2,48 %	146
Emphysema	2.516	2,24 %	—
Edema	2.303	2,05 %	—
Fibrosis	1.686	1,50 %	—
Pneumonia	1.431	1,28 %	120
Hernia	227	0,20 %	—
Total de cajas			984

Las imágenes pueden tener varias etiquetas, por lo que los porcentajes no suman 100 %. En el archivo de cajas la categoría Infiltration figura como “Infiltrate”.

División efectiva por paciente. Aplicando el plan del Hito 1 se obtuvo la división del Cuadro 5. Se verificó por código que ningún paciente aparece en más de un conjunto (prueba PM1).

Cuadro 5: División del dataset por paciente

Conjunto	Imágenes	Pacientes	Origen
Entrenamiento	76.277	24.647	`train_val_list.txt` (88 % de los pacientes)
Validación	10.247	3.361	`train_val_list.txt` (12 % de los pacientes)
Prueba	25.596	2.797	`test_list.txt` (división oficial)
Total	112.120	30.805	

Tres consecuencias para el diseño:

- **Desbalance fuerte:** Infiltration tiene unas 88 veces más imágenes que Hernia. Por eso se usa pérdida ponderada por clase (pesos en el Cuadro 15) y se reportará el AUC-ROC de cada patología, no solo el promedio.
- **Localización parcial:** las cajas cubren solo 8 de las 14 patologías. Consolidation, Pleural Thickening, Emphysema, Edema, Fibrosis y Hernia no tienen cajas, así que su ubicación solo puede estimarse con Grad-CAM y no puede evaluarse con IoU.
- **Clase “No Finding”:** el modelo mantiene 14 salidas y trata una imagen sana como aquella donde todas las probabilidades son bajas.

Para probar la aplicación con DICOM se usan radiografías de tórax DICOM de uso público y archivos DICOM generados a partir de imágenes del dataset.

6.4 Perfiles de Usuario

Cuadro 6: Perfiles de usuario

Perfil	Socioeconómico y cultural	Ocupacional	Etario	Características físicas, fisiológicas, psicológicas	Otros
Médico radiólogo / especialista	General	Profesional de la salud que interpreta imágenes	Adulto	Sin restricciones particulares; requiere visualización de alta calidad	Usa el sistema como segunda opinión
Médico de urgencias / general	General	Profesional que decide con rapidez ante la sospecha de patología pulmonar	Adulto	Trabaja bajo presión de tiempo	Requiere resultados rápidos y claros
Estudiante o investigador	General	Estudiante de medicina, ingeniería o investigador en IA médica	Joven adulto / adulto	Sin restricciones particulares	Usa el sistema con fines docentes o de evaluación

›

7 Planificación del Proyecto

7.1 Objetivo General (Goal)

Desarrollar un sistema de apoyo al análisis de radiografías de tórax, basado en Deep Learning, que detecte patologías pulmonares y su ubicación a partir de una imagen DICOM, utilizando el dataset NIH ChestX-ray14.

7.2 Objetivos Específicos

Ver sección 1.1.

7.3 Actividades y Milestones

Semanas según el calendario del curso (la semana 14 va del 02/11 al 06/11). El estado corresponde al corte de la semana 14. El detalle por tarea, con el autor de cada una y el enlace a su evidencia, está en la Bitácora 2.

Cuadro 7: Actividades y milestones (estado a la semana 14)

Elemento	Responsable	Inicio	Término	Estado	Avance
A1.1 Análisis del dataset y estadísticas de clases (O1)	Nicolas Severino	21/09 (S8)	02/10 (S9)	Completada	100 %
A1.2 Pipeline de datos: división por paciente y preprocesamiento (O1)	Benjamin Arias	12/10 (S11)	23/10 (S12)	Completada	100 %
A2.1 Modelo base: entorno, clasificador DenseNet121 y primer entrenamiento (O2)	Hans Varela	12/10 (S11)	06/11 (S14)	En curso	83 %
A2.2 Ponderación de clases, ajuste y evaluación AUC-ROC (O2)	Hans Varela	02/11 (S14)	20/11 (S16)	En curso	25 %
A3.1 Localización con Grad-CAM, cajas e IoU (O3)	Karime Jarufe	02/11 (S14)	20/11 (S16)	En curso	67 %
A4.1 Lectura de DICOM y consistencia con PNG (O4)	Benjamin Arias	12/10 (S11)	30/10 (S13)	En curso	75 %
A4.2 Interfaz gráfica: mockups, implementación e integración (O4)	Karime Jarufe	28/09 (S9)	27/11 (S17)	Completada	100 %
A5.1 Diseño del plan de pruebas (O5)	Nicolas Severino	28/09 (S9)	09/10 (S10)	Completada	100 %
A5.2 Ejecución de pruebas e informe final (O5)	Nicolas Severino	02/11 (S14)	04/12 (S18)	En curso	33 %
G1.1 Gestión: documento, presentaciones, bitácoras y reuniones semanales	Todo el equipo	21/09 (S8)	04/12 (S18)	En curso	66 %
G1.2 Definición y delimitación del problema	Todo el equipo	21/09 (S8)	02/10 (S9)	Completada	100 %
Milestone 1: Análisis y Diseño (documento, presentación y Bitácora 1)	Todo el equipo	21/09 (S8)	09/10 (S10)	Completada	100 %
Milestone 2 (Bitácora 2): avance con modelo base y lector DICOM	Todo el equipo	12/10 (S11)	06/11 (S14)	En curso	85 %
Milestone 3: sistema integrado con localización e interfaz	Todo el equipo	02/11 (S14)	27/11 (S17)	En curso	60 %
Milestone 4: presentación en la Feria y evaluación final (Bitácora 3)	Todo el equipo	23/11 (S17)	04/12 (S18)	No iniciada	0 %

Desviaciones respecto del plan del Hito 1:

- **Adelantos:** la interfaz gráfica, su integración con todos los módulos y el Grad-CAM con cajas estaban planificados hasta las semanas 16–17 y ya funcionan (sección 11).
- **Atraso:** el Milestone 2 pedía un modelo base entrenado. El modelo está implementado y se validó con un entrenamiento corto sobre un subconjunto (Cuadro 16), pero falta el entrenamiento completo sobre las 76.277 imágenes, que requiere de 6 a 8 horas de GPU. Se reprograma para la semana 15; de él dependen la evaluación AUC-ROC (T2.2.2) y la de IoU (T3.1.3).
- **Pendiente:** la prueba de consistencia DICOM/PNG (T4.1.2) se hizo con una imagen sintética de 8 bits; falta repetirla con radiografías reales convertidas a DICOM de 16 bits.

7.4 Carta Gantt

Planificación por semana del calendario del curso. El color indica el estado a la semana 14: completada, en curso o parcialmente lograda, no iniciada. La columna S14 corresponde a esta entrega.

Cuadro 8: Carta Gantt (estado a la semana 14)

Actividad	S8 21/09	S9 28/09	S10 05/10	S11 12/10	S12 19/10	S13 26/10	**S14 02/11**	S15 09/11	S16 16/11	S17 23/11	S18 30/11
A1.1 Análisis del dataset											
A1.2 Pipeline de datos											
A2.1 Modelo base											
A2.2 Ajuste y evaluación											
A3.1 Localización (Grad-CAM)											
A4.1 Lectura de DICOM											
A4.2 Interfaz gráfica											
A5.1 Diseño de pruebas											
A5.2 Ejecución de pruebas											
G1.1 Gestión y seguimiento											
G1.2 Definición del problema											
Milestone 1											
Milestone 2 (Bitácora 2)											
Milestone 3											
Milestone 4											
Entregas del curso			B1				B2				B3

8 Diseño de Arquitectura del Sistema

8.1 Diagrama de Contexto

El sistema se modela como una caja negra con los siguientes entes externos (Figura 1):

- **Usuario → Sistema:** archivo DICOM, umbral de decisión, órdenes de análisis y exportación.
- **Sistema → Usuario:** patologías detectadas con probabilidad, imagen con regiones marcadas, mensajes de estado y error.
- **Sistema de archivos ↔ Sistema:** entrega archivos DICOM y los pesos del modelo entrenado; recibe los resultados exportados.
- **Dataset NIH ChestX-ray14 → Sistema** (solo en la fase de desarrollo): imágenes, etiquetas y cajas delimitadoras para entrenamiento y evaluación.

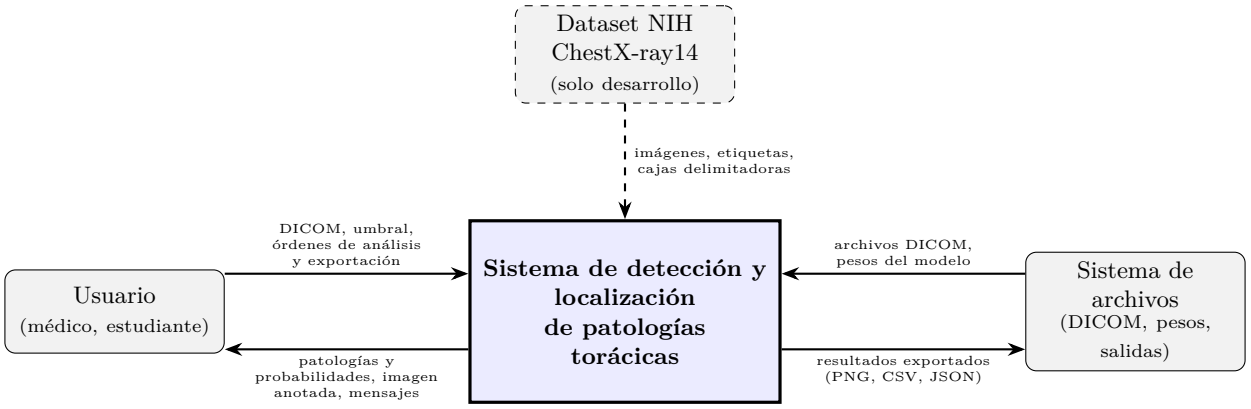


Figura 1: Diagrama de contexto.

8.2 Diagrama de Arquitectura

Flujo principal de información entre módulos: GUI → DCM (archivo DICOM) → PRE (imagen normalizada) → CLS (probabilidades por patología) → LOC (mapas y cajas) → GUI (resultados). En la fase de desarrollo, TRN usa PRE para entrenar y evaluar a CLS y LOC, y entrega los pesos del modelo.

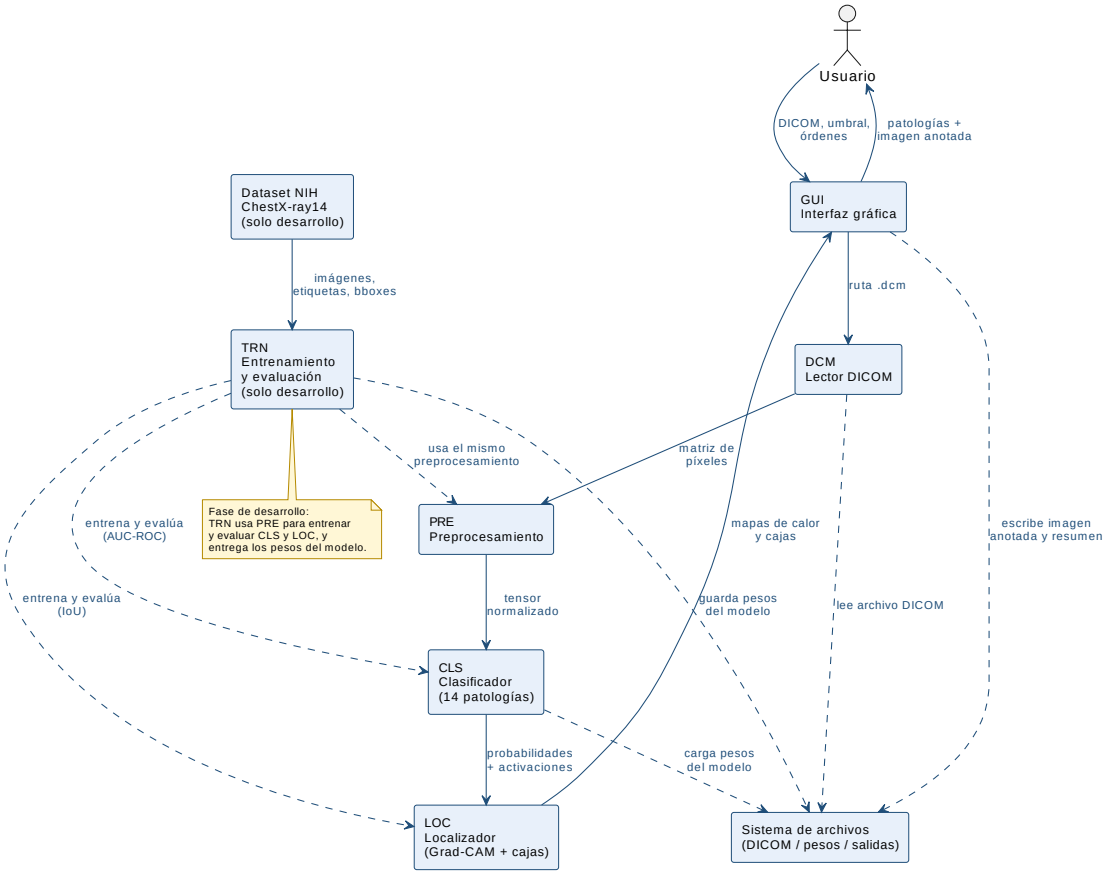


Figura 2: Diagrama de arquitectura del sistema.

8.3 Enumeración de Módulos

Cuadro 9: Módulos de la arquitectura del sistema

Módulo	Propósito	Sección
Lector DICOM (DCM)	Lee y valida el archivo DICOM, extrae la matriz de píxeles y la lleva a 8 bits.	8.5.1
Preprocesamiento (PRE)	Convierte la imagen al formato de entrada del modelo: redimensionamiento, tres canales y normalización. Se usa tanto en entrenamiento como en inferencia.	8.5.2
Clasificador (CLS)	Modelo convolucional que entrega la probabilidad de cada una de las 14 patologías.	8.5.3
Localizador (LOC)	Genera mapas de activación a partir del clasificador y los convierte en cajas sobre la imagen.	8.5.4
Interfaz gráfica (GUI)	Permite cargar la imagen, lanzar el análisis, ajustar el umbral y ver y exportar los resultados.	8.5.5, 9
Entrenamiento y evaluación (TRN)	Gestiona los datos del dataset, entrena el modelo y calcula métricas (AUC-ROC, IoU).	8.5.6

8.4 Matriz de Requisitos Funcionales y Módulos

Cuadro 10: Matriz de requisitos funcionales y módulos

Requisito	DCM	PRE	CLS	LOC	GUI	TRN
RF1 Cargar DICOM	X				X	
RF2 Validar archivo	X				X	
RF3 Visualizar imagen					X	
RF4 Preprocesar imagen		X				
RF5 Detectar patologías			X			
RF6 Localizar patologías				X		
RF7 Mostrar resultados					X	
RF8 Ajustar umbral					X	
RF9 Exportar resultados					X	
RF10 Entrenar y evaluar		X	X	X		X

No hay filas ni columnas vacías. La mayor concentración está en la GUI, lo que es esperable porque agrupa todas las funciones de interacción con el usuario.

8.5 Definición de Módulos

Se sigue un diseño modular: cada módulo expone una interfaz acotada, de modo que se puedan reemplazar componentes (por ejemplo, cambiar el modelo o el método de localización) sin afectar al resto. En el Hito 1 los módulos se definieron como clases; en la implementación se optó por funciones agrupadas por módulo, que resultaron más simples de probar de forma aislada con pytest. Se indica entre paréntesis el archivo donde está implementado cada uno.

8.5.1 Módulo DCM – Lector DICOM (`06_gui.py`)

- **Propósito:** leer un archivo DICOM y entregar una matriz de píxeles de 8 bits.
- **General:** entra la ruta del archivo; sale la imagen en escala de grises `uint8` o un error de validación.
- **Marco técnico:** estándar DICOM [6], librería pydicom. Valida que exista `PixelData`, que la interpretación fotométrica sea MONOCHROME1 o MONOCHROME2 y que la imagen sea 2D. Aplica *RescaleSlope/Intercept*; luego lleva a 8 bits usando la ventana del archivo (*WindowCenter/Width*) si existe, o los percentiles 0,5–99,5 si no. Invierte la imagen si es MONOCHROME1.
- **Estructura:** `load_dicom(path) -> np.ndarray uint8`; lanza `ValueError` con un mensaje legible si el archivo no es válido.

8.5.2 Módulo PRE – Preprocesamiento (`05_entrenar.py`)

- **Propósito:** dejar toda imagen en el mismo formato de entrada del modelo, sin importar si viene de DICOM o del dataset.
- **General:** entra una matriz `uint8`; sale un tensor normalizado de 224×224×3.
- **Marco técnico:** redimensionamiento bilineal a 224×224, replicación a tres canales y normalización de DenseNet (`preprocess_input`). En entrenamiento se agrega aumento de datos: rotación ±10°, zoom ±10 %, brillo y contraste ±10 %, *sin volteo horizontal*. La misma función se usa en entrenamiento y en la aplicación, lo que evita diferencias entre ambos casos.
- **Estructura:** `to_224_rgb(img)` y `normalize(img_u8)`; `make_augmenter()` solo en entrenamiento.

8.5.3 Módulo CLS – Clasificador (`05_entrenar.py`)

- **Propósito:** estimar la probabilidad de cada patología.
- **General:** entra el tensor de imagen; salen 14 probabilidades.

- **Marco técnico:** DenseNet-121 [4] con pesos de ImageNet, *global average pooling*, *dropout* 0,3 y capa densa de 14 salidas sigmoide. Pérdida: entropía cruzada binaria con peso por clase en el término positivo. Las capas de *batch normalization* permanecen congeladas para estabilizar el ajuste fino con lotes pequeños.
- **Estructura:** `build_model()`, `make_weighted_bce(pos_weight)`, `compile_model()`; el modelo entrenado se guarda en `models/modelo_base.keras`.

8.5.4 Módulo LOC – Localizador (`06_gui.py`)

- **Propósito:** indicar dónde está la región asociada a cada patología detectada.
- **General:** entran el tensor de imagen, el clasificador y el índice de la patología; salen un mapa de calor normalizado y, según la patología, hasta dos cajas delimitadoras o el contorno de la región.
- **Marco técnico:** Grad-CAM [3] sobre la capa `relu` (última activación convolucional de DenseNet-121), calculado con `tf.GradientTape`. El mapa se binariza con un umbral de 0,5 y se extraen sus componentes conexas con OpenCV, descartando las menores al 0,5 % del área.
- **Hallazgos focales y difusos.** Una caja delimitadora describe bien una lesión con borde definido, pero es imprecisa para una opacidad difusa: un infiltrado o un edema se extienden de forma irregular, a veces por ambos pulmones, y la caja termina cubriendo mucho tejido sano. Por eso LOC trata las patologías en dos grupos:
  - *Focales* (Nodule, Mass, Cardiomegaly): se dibuja hasta dos cajas, las de las componentes más grandes.
  - *Difusas o de forma irregular* (Infiltration, Consolidation, Pneumonia, Edema, Atelectasis, Effusion, Pneumothorax, Emphysema, Fibrosis, Pleural Thickening, Hernia): no se dibuja caja. Se muestra el mapa de calor y el contorno de la región que supera el umbral (`cv2.findContours`, material de contornos de la Unidad 7).
- **Evaluación.** Para las clases focales se usa IoU con las cajas reales. Para las difusas, el IoU castiga injustamente a un mapa que acierta en la zona pero no en el rectángulo, así que se medirá qué fracción de la caja real queda cubierta por la región del mapa y si el punto de máxima activación cae dentro de ella (*pointing game*).
- **Estructura:** `heatmap(x, class_idx)`, `to_boxes(hm, thr, orig_shape)` para las clases focales y `to_contours(hm, thr)` para las difusas.
- **Estado:** Grad-CAM y `to_boxes` están implementados; hoy la interfaz dibuja cajas para todas las clases. La separación focal/difusa y `to_contours` se implementan en la semana 15.

8.5.5 Módulo GUI – Interfaz gráfica (`06_gui.py`)

- **Propósito:** permitir al usuario usar el sistema sin conocimientos técnicos.
- **General:** entradas y salidas según los Cuadros 2 y 3.
- **Marco técnico:** Gradio, ejecutado como servidor local en `127.0.0.1`. Antes de iniciar verifica que existan el modelo y las dependencias, y registra la versión y el hash del modelo cargado.
- **Estructura:** manejadores `on_upload`, `on_analizar`, `on_render` y `on_exportar`, uno por evento del Cuadro 2.

8.5.6 Módulo TRN – Entrenamiento y evaluación (scripts `01` a `05`)

- **Propósito:** preparar los datos, entrenar el modelo y evaluarlo.
- **General:** entran el dataset y la configuración; salen los pesos del modelo, los registros de métricas y los reportes.
- **Marco técnico:** verificación del dataset, división por paciente, cálculo de pesos por clase, subconjunto estratificado para pruebas rápidas y entrenamiento en dos etapas (cabeza y luego ajuste fino de las últimas 60 capas), con guardado del mejor modelo según `val_auc` y semilla fija 42.
- **Estructura:** `01_verificar_dataset.py` → `02_split_dataset.py` → `03_calcular_pesos.py` → `04_crear_subconjunto.py` → `05_entrenar.py`.

9 Diseño de Interfaces

9.1 Modelo de Navegación

El punto de partida es la **Pantalla Principal**. La aplicación es de una sola ventana principal con un diálogo auxiliar:

1. Pantalla Principal (vacía) → evento *Cargar DICOM* → Diálogo de selección de archivo.
2. Diálogo de selección → archivo válido → Pantalla Principal (imagen cargada); archivo inválido → Mensaje de error → vuelve a la Pantalla Principal.
3. Pantalla Principal (imagen cargada) → evento *Analizar* → Pantalla Principal (con resultados).
4. Pantalla Principal (con resultados) → *Cambiar umbral* → se actualiza la misma pantalla; *Exportar* → Diálogo de guardado → vuelve a la pantalla; *Cargar DICOM* → reinicia el flujo.

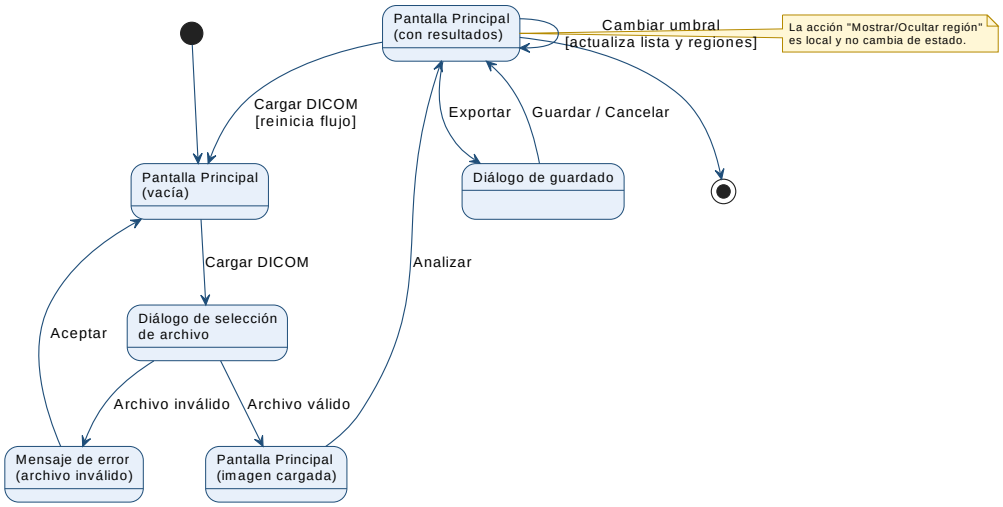


Figura 3: Diagrama de modelo de navegación.

9.2 Prototipos de Interfaces Usuarias

9.2.1 Prototipo 1 – Pantalla Principal

Ventana dividida en tres zonas:

- **Izquierda:** visor de la radiografía, con las regiones detectadas superpuestas como cajas de colores con la etiqueta de la patología.
- **Derecha:** panel de resultados con la lista de patologías, su probabilidad (barra y porcentaje) y una casilla para mostrar u ocultar cada región.
- **Inferior:** botones *Cargar DICOM*, *Analizar*, *Exportar*, un control deslizante *Umbral*, y una barra de estado con el aviso permanente “Herramienta de apoyo; no reemplaza el diagnóstico médico”.

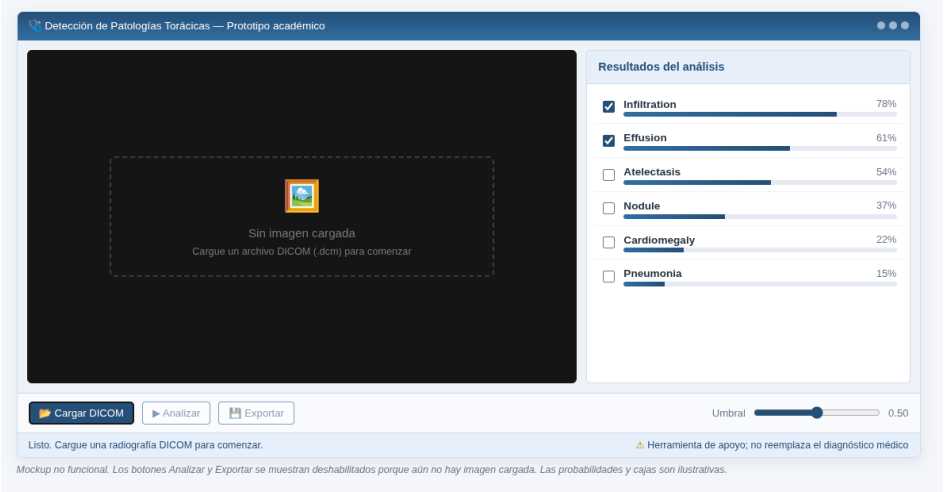


Figura 4: Prototipo 1 – Pantalla Principal (mockup del Hito 1).

Cuadro 11: Interacciones de la pantalla principal

Evento	Interacción	Acción	Objeto afectado
Cargar DICOM	Clic en el botón “Cargar DICOM”	Se abre el diálogo de selección; si el archivo es válido se muestra la imagen	Visor de radiografía
Analizar	Clic en el botón “Analizar”	Se ejecuta el modelo y se llenan los resultados	Panel de resultados, visor
Cambiar umbral	Mover el control deslizante “Umbral”	Se actualizan la lista y las regiones mostradas	Panel de resultados, visor
Mostrar/ocultar región	Marcar o desmarcar la casilla de una patología	Se muestra u oculta su región sobre la imagen	Visor de radiografía
Exportar	Clic en el botón “Exportar”	Se guardan la imagen anotada y el resumen	Archivos de salida

9.2.2 Prototipo 2 – Mensaje de error

Ventana emergente simple con el texto del problema (por ejemplo, “El archivo no es un DICOM válido”) y un botón *Aceptar*, que cierra el mensaje y vuelve a la Pantalla Principal.



Figura 5: Prototipo 2 – Mensaje de error.

9.3 Interfaz implementada (Hito 2)

La interfaz se implementó siguiendo el Prototipo 1 (Figura 6). Respecto del mockup se agregaron dos casillas, *Mapa de calor* y *Cajas*, para mostrar u ocultar cada capa de la visualización, y un panel de *Archivos exportados*. La exportación genera tres archivos: la imagen anotada (PNG), las probabilidades (CSV) y un resumen con metadatos y versión del modelo (JSON).

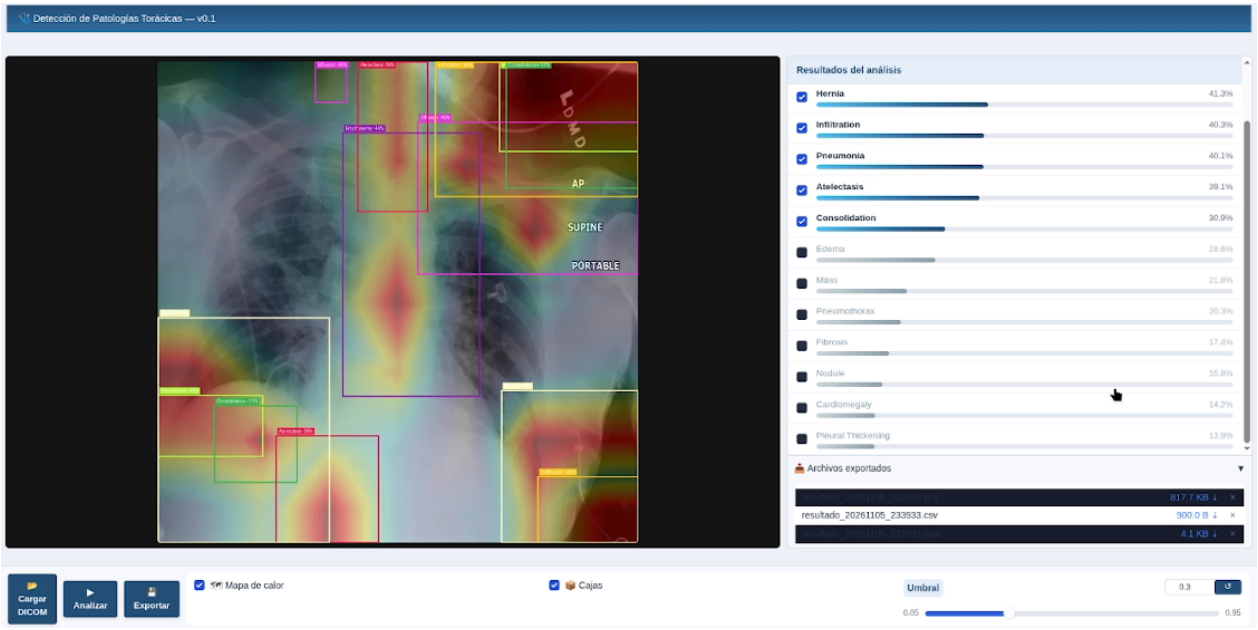


Figura 6: Interfaz implementada: resultados con umbral 0,30, mapa de calor Grad-CAM y cajas por patología.

9.4 Ejemplo de localización sobre la imagen

La Figura 7 muestra cómo se ve la localización para un hallazgo concreto, con la aplicación real:

1. El usuario carga la radiografía DICOM y presiona *Analizar*.
2. El panel derecho lista las 14 patologías ordenadas por probabilidad. En este caso, la más alta es Effusion (derrame pleural), con 44,6 %.
3. El usuario sube el umbral a 0,44 y deja marcada solo Effusion. El visor muestra el mapa de calor de esa patología, donde rojo es la zona que más influyó en la predicción, y la región correspondiente sobre la imagen.
4. Con las casillas *Mapa de calor* y *Cajas* se puede mostrar u ocultar cada capa para comparar con la radiografía original.

Como el modelo actual es preliminar (sección 11), la ubicación del ejemplo todavía no es clínicamente confiable. La figura muestra el funcionamiento de la interfaz, no un resultado diagnóstico. Effusion es un hallazgo difuso, así que con el cambio descrito en la sección 8.5.4 se mostrará con contorno en vez de caja.

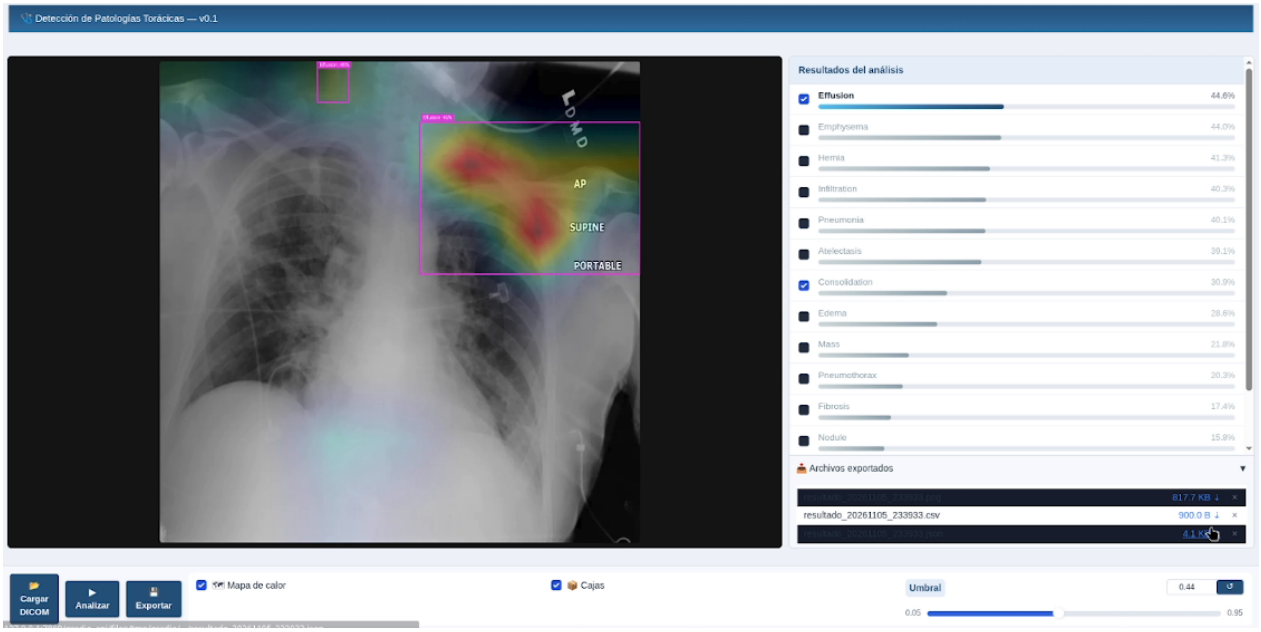


Figura 7: Ejemplo de localización: Effusion seleccionada con umbral 0,44; mapa de calor Grad-CAM y región sobre la radiografía.

10 Diseño de Pruebas

Se mantiene el plan del Hito 1 y se agrega el estado de ejecución a la semana 14. Las pruebas unitarias se implementaron con pytest, con datos sintéticos generados en `conftest.py`, de modo que se pueden ejecutar sin el dataset ni el modelo entrenado.

Pruebas del modelo

Cuadro 12: Pruebas del modelo

ID	Prueba	Criterio de aceptación	Estado (S14)
PM1	No hay pacientes repetidos entre entrenamiento, validación y prueba	0 pacientes en común	Aprobada (4 tests)
PM2	AUC-ROC por patología sobre `test_list.txt`	Se reporta para las 14 patologías; promedio cercano a la literatura	Pendiente: requiere el entrenamiento completo
PM3	IoU de las cajas generadas contra las 984 cajas reales	Se reporta IoU y proporción de aciertos a distintos umbrales	Pendiente: requiere el entrenamiento completo
PM4	Reproducibilidad: dos entrenamientos con la misma semilla	Resultados equivalentes dentro de una tolerancia definida	Pendiente

Pruebas unitarias de módulos

Cuadro 13: Pruebas unitarias de módulos

ID	Prueba	Criterio de aceptación	Estado (S14)
PU1	DCM lee un DICOM válido (MONOCHROME1 y MONOCHROME2, 8, 12 y 16 bits)	Matriz con dimensiones y rango esperados	Aprobada (4 tests)
PU2	DCM rechaza un archivo que no es DICOM o no existe	Error controlado	Aprobada (2 tests)
PU3	PRE entrega el mismo tamaño y rango para PNG y DICOM	Tensores equivalentes	Parcial: forma y rango aprobados (3 tests); falta comparar con radiografías reales en DICOM de 16 bits
PU4	CLS entrega 14 valores entre 0 y 1	Dimensión y rango correctos	Aprobada (3 tests)
PU5	LOC entrega cajas dentro de los límites de la imagen	Coordenadas válidas	Aprobada (3 tests)

Pruebas de sistema e interfaz

Cuadro 14: Pruebas de sistema e interfaz

ID	Prueba	Criterio de aceptación	Estado (S14)
PS1	Flujo completo: cargar DICOM, analizar, ver resultados	Resultados en menos de 10 segundos (RNF1)	Flujo demostrado en video; falta medir el tiempo
PS2	Cambiar el umbral	La lista y las regiones se actualizan	Demostrado en video; falta registro formal
PS3	Exportar resultados	Se generan los archivos esperados	Demostrado en video (PNG, CSV y JSON); falta registro formal
PS4	Cargar un archivo inválido	Mensaje de error, la aplicación no se cae	Pendiente (cubierto a nivel unitario por PU2)
PS5	Prueba de usabilidad con usuarios del perfil objetivo	Completan la tarea en no más de 3 pasos (RNF2)	Pendiente (semana 17)

11 Avance de la Solución

Esta sección resume lo implementado al corte de la semana 14. Cada resultado tiene su código, registro y captura en la carpeta de evidencias, enlazada desde la Bitácora 2.

11.1 Datos (O1)

- **Verificación del dataset:** los 112.120 registros, los 30.805 pacientes y los conteos de las 15 categorías coinciden con los publicados [1].
- **Análisis estadístico:** distribución de clases, número de hallazgos por imagen (Figura 8) y matriz de co-ocurrencia. Los pares que más aparecen juntos respecto de lo esperado por azar (*lift*) son Edema + Pneumonia (11,6), Pneumothorax + Emphysema (6,3) y Fibrosis + Pleural Thickening (3,5), asociaciones coherentes con la fisiopatología.
- **División por paciente:** Cuadro 5, sin pacientes compartidos.
- **Pesos por clase:** calculados sobre el conjunto de entrenamiento (Cuadro 15). Se usa la raíz de la razón negativos/positivos para no sobrecorregir: con la razón lineal, Hernia tendría un peso de 662 frente a 5,3 de Infiltration.

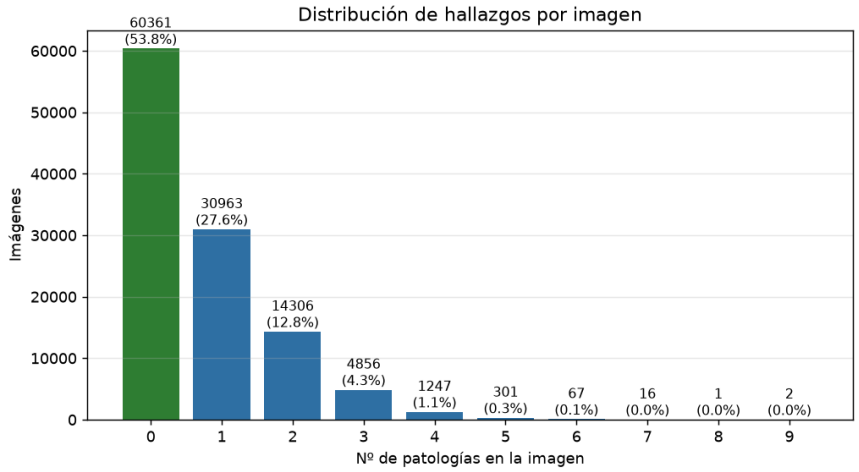


Figura 8: Número de hallazgos por imagen en NIH ChestX-ray14: el 53,84 % no tiene hallazgos y el 18,55 % tiene dos o más.

Cuadro 15: Pesos por clase en el conjunto de entrenamiento (76.277 imágenes)

Patología	Positivos	Frec.	Peso	Patología	Positivos	Frec.	Peso
Atelectasis	7.236	9,49 %	3,09	Effusion	7.638	10,01 %	3,00
Consolidation	2.542	3,33 %	5,39	Pneumonia	765	1,00 %	9,94
Infiltration	12.190	15,98 %	2,29	Pleural Thick.	1.931	2,53 %	6,20
Pneumothorax	2.337	3,06 %	5,62	Cardiomegaly	1.509	1,98 %	7,04
Edema	1.234	1,62 %	7,80	Nodule	4.146	5,44 %	4,17
Emphysema	1.295	1,70 %	7,61	Mass	3.554	4,66 %	4,52
Fibrosis	1.084	1,42 %	8,33	Hernia	115	0,15 %	25,73

11.2 Modelo base (O2)

- **Entorno:** TensorFlow 2.21 sobre ROCm, con la GPU detectada correctamente.
- **Modelo:** DenseNet-121 con cabeza de 14 salidas y pérdida ponderada (sección 8.5.3).
- **Prueba de funcionamiento (*sanity check*):** antes de lanzar el entrenamiento completo (6–8 h de GPU) se entrenó la cabeza durante 2 épocas sobre un subconjunto estratificado de unas 2.000 imágenes,

validando con 500 imágenes de validación. El objetivo no era obtener un buen modelo, sino comprobar que el pipeline completo funciona y que la red aprende: el AUC de validación sube y la pérdida baja (Cuadro 16). Este modelo preliminar es el que usa hoy la interfaz.

Cuadro 16: Prueba de funcionamiento del entrenamiento (subconjunto, solo cabeza)

Época	AUC entren.	Pérdida entren.	AUC valid.	Pérdida valid.
1	0,529	0,905	0,565	0,573
2	0,564	0,852	0,611	0,545

Un AUC de 0,61 está lejos del valor de referencia de la literatura (alrededor de 0,84 de promedio para CheXNet [2]), lo que es esperable con el 2,6 % de los datos, 2 épocas y el backbone congelado. El entrenamiento completo (3 épocas de cabeza y 10 de ajuste fino sobre las 76.277 imágenes) queda para la semana 15.

11.3 Localización (O3)

Grad-CAM y la conversión del mapa a cajas están implementados e integrados en la interfaz (Figuras 6 y 7). A partir de la revisión del Hito 1 se rediseñó la salida para los hallazgos difusos, que se mostrarán con contorno y no con caja (sección 8.5.4). Como el modelo actual es preliminar, los mapas todavía no se concentran de forma confiable en la región patológica; por eso la evaluación con IoU (PM3) se hará con el modelo completo. La extracción de contornos se basa en el material de la Unidad 7 del curso.

11.4 Lectura DICOM (O4)

El lector maneja MONOCHROME1 y MONOCHROME2, datos de 8, 12 y 16 bits, ventana del archivo o percentiles, y rechaza archivos inválidos con un mensaje claro (PU1 y PU2). En la Figura 6 se ve una radiografía DICOM de prueba (proyección AP, paciente en decúbito) cargada y analizada. La prueba de consistencia con PNG se hizo con una imagen sintética de 8 bits y dio diferencia 0; falta repetirla con radiografías reales del dataset convertidas a DICOM de 16 bits, que es el caso donde pueden aparecer diferencias.

11.5 Interfaz e integración (O4)

La aplicación integra los cinco módulos de inferencia (GUI, DCM, PRE, CLS y LOC) y permite cargar, analizar, ajustar el umbral, mostrar u ocultar mapa y cajas, y exportar. El flujo completo está registrado en un video demostrativo de 2,5 minutos.

11.6 Pruebas (O5)

Se ejecutaron 26 pruebas unitarias en 8 archivos, todas aprobadas, sin fallos ni advertencias (Figura 9). Las pruebas que requieren el modelo entrenado (PM2–PM4) y las de sistema (PS1–PS5) quedan para los próximos ciclos.

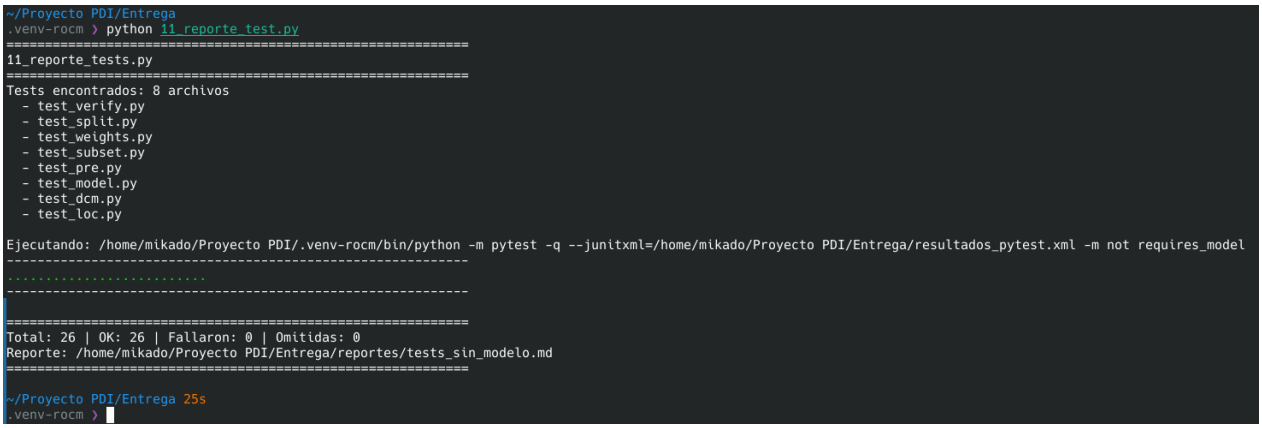


Figura 9: Ejecución de las pruebas unitarias: 26 de 26 aprobadas.

11.7 Riesgos y próximos pasos

- **Entrenamiento completo** (semana 15): requiere de 6 a 8 horas de GPU dedicada; se observaron congelamientos del sistema operativo bajo carga, mitigados haciendo que la memoria de la GPU se reserve de forma gradual (*memory growth*).
- **Evaluaciones AUC-ROC e IoU** (semanas 15–16): dependen del modelo completo.
- **Localización por tipo de hallazgo** (semana 15): implementar `to_contours` y la separación focal/difusa en la interfaz.
- **Consistencia DICOM/PNG con datos reales** (semana 15).
- **Pruebas de sistema y usabilidad** (semana 17).
- **Consulta pendiente al profesor:** si Grad-CAM es suficiente para la localización o se espera un detector entrenado.

12 Conclusiones

El Hito 1 estableció las bases de análisis y diseño del sistema. En el Hito 2 esa arquitectura modular se llevó a código: el pipeline de datos está completo y verificado, el clasificador DenseNet-121 con pérdida ponderada está implementado y su entrenamiento fue validado en un subconjunto, la localización con Grad-CAM funciona, y la aplicación lee DICOM y muestra probabilidades, mapas y cajas de extremo a extremo. Las 26 pruebas unitarias aprobadas respaldan cada módulo de forma aislada.

El principal pendiente es el entrenamiento completo del modelo, del que dependen las métricas finales (AUC-ROC e IoU). Como la integración y la interfaz se adelantaron respecto del plan, el equipo puede concentrar las semanas 15 y 16 en entrenar, evaluar y ajustar el modelo, y la semana 17 en las pruebas de sistema y usabilidad.

13 Referencias

1. X. Wang, Y. Peng, L. Lu, Z. Lu, M. Bagheri y R. M. Summers, “ChestX-ray8: Hospital-scale chest X-ray database and benchmarks on weakly-supervised classification and localization of common thorax diseases,” en *Proc. IEEE CVPR*, 2017, pp. 3462–3471. (arXiv:1705.02315)
2. P. Rajpurkar et al., “CheXNet: Radiologist-level pneumonia detection on chest X-rays with deep learning,” arXiv:1711.05225, 2017.
3. R. R. Selvaraju et al., “Grad-CAM: Visual explanations from deep networks via gradient-based localization,” en *Proc. IEEE ICCV*, 2017.
4. G. Huang, Z. Liu, L. van der Maaten y K. Q. Weinberger, “Densely connected convolutional networks,” en *Proc. IEEE CVPR*, 2017.

5. S. Ren, K. He, R. Girshick y J. Sun, “Faster R-CNN: Towards real-time object detection with region proposal networks,” en *Advances in Neural Information Processing Systems (NIPS)*, 2015.
6. NEMA, “Digital Imaging and Communications in Medicine (DICOM) Standard, PS3,” National Electrical Manufacturers Association.
7. H.-C. Shin et al., “Learning to read chest X-rays: Recurrent neural cascade model for automated image annotation,” en *Proc. IEEE CVPR*, 2016, pp. 2497–2506.
8. Lunit, “Lunit INSIGHT CXR Triage receives FDA 510(k) clearance,” comunicado de prensa, nov. 2021. `https://www.appliedradiology.com/news/lunit-insight-cxt-triage-gets-fda-ok`
9. Qure.ai, “Qure.ai nets six new indications cleared by the FDA (qXR-Detect),” comunicado de prensa, feb. 2026. `https://qure.ai/news_press_coverages/qure.ai-nets-six-new-indications-cleared-by-the-fda-taking-the-chest-x-ray-crown-in-the-radiology-ai-race`
10. Annalise.ai, “Annalise Enterprise scores big with series of regulatory clearances,” comunicado de prensa, ago. 2023. `https://www.itnonline.com/content/annalise-enterprise-scores-big-series-regulatory-clearances`
11. Sectra, “Sectra acquires Oxipit, advancing autonomous AI capabilities in diagnostic imaging,” comunicado de prensa, mar. 2026; Oxipit, “ChestEye imaging suite receives CE certification”. `https://radiologybusiness.com/node/130946`
12. P. Putha et al. (Qure.ai), “Application of deep learning for medical imaging evaluation,” patente US 10,733,727 B2, 2020. `https://patents.google.com/patent/US10733727`
13. P. Putha et al. (Qure.ai), “Method and system for medical imaging evaluation,” patente US 10,755,413 B1, 25 ago. 2020.