UNIVERSIDAD TECNICA
FEDERICO SANTA MARIA

DEPARTAMENTO DE
ELECTRONICA

Detección y localización de patologías torácicas en radiografías mediante Deep Learning

Documento de Análisis y Diseño — Hito 1

Fecha	6 de noviembre de 2026
Integrantes:	Benjamin Esteban Arias Vega
	Karime Andrea Jarufe Escobar
	Nicolas Eduardo Severino Palma
	Hans David Varela Antilao
Asignatura:	TEL328
Profesor:	Marcos Zúñiga
Versión:	1.0 (Hito 1)

Índice

1 Introducción **4**
1.1 Objetivos . . . 4

2 Diagnóstico e identificación del problema, desafío u oportunidad **5**

3 Propuesta de solución **5**

4 Estado del Arte y de la Técnica **6**

5 Requisitos del Sistema **6**
5.1 Requisitos Funcionales . . . 6
5.2 Requisitos no funcionales . . . 6
5.3 Requisitos de Interfaces . . . 7

6 Requisitos de Ambiente **7**
6.1 Hardware de Desarrollo . . . 7
6.2 Software de Desarrollo . . . 7
6.3 Datasets e Imágenes/Videos de Prueba . . . 7
6.4 Perfiles de Usuario . . . 8

7 Planificación del Proyecto **9**
7.1 Objetivo General (Goal) . . . 9
7.2 Objetivos Específicos . . . 9
7.3 Actividades y Milestones . . . 9
7.4 Carta Gantt . . . 10

8 Diseño de Arquitectura del Sistema **11**
8.1 Diagrama de Contexto . . . 11
8.2 Diagrama de Arquitectura . . . 12
8.3 Enumeración de Módulos . . . 13
8.4 Matriz de Requisitos Funcionales y Módulos . . . 13
8.5 Definición de Módulos . . . 13

9 Diseño de Interfaces **15**
9.1 Modelo de Navegación . . . 15
9.2 Prototipos de Interfaces Usuarias . . . 15

10 Diseño de Pruebas **17**

11 Conclusiones **18**

12 Referencias **19**

Índice de figuras

1 Diagrama de contexto. . . . 11
2 Diagrama de arquitectura, a incorporar como figura en la versión con gráficos. . . . 12
3 Diagrama de Modelo de Navegación . . . 15
4 Prototipo 1 – Pantalla Principal. . . . 16
5 Prototipo 2 – Mensaje de error . . . 16

Índice de cuadros

1 Eventos externos . . . 7
2 Respuestas del sistema . . . 7
3 Distribución de diagnósticos y cajas delimitadoras (112.120 imágenes) . . . 8
4 Perfiles de usuario . . . 8

5 Actividades y milestones 9
6 Carta Gantt 10
7 Módulos de la arquitectura del sistema 13
8 Matriz de requisitos funcionales y módulos 13
9 Interacciones de la pantalla principal 16
10 Interacción del mensaje de error 17
11 Pruebas del modelo 17
12 Pruebas unitarias de módulos 17
13 Pruebas de sistema e interfaz 17

1. Introducción

La radiografía de tórax es uno de los exámenes de imagenología más frecuentes y de menor costo en la práctica clínica. Sin embargo, su interpretación es compleja: varias patologías pulmonares se ven parecidas entre sí (por ejemplo, infiltrado, consolidación y neumonía), y su diagnóstico visual depende de la experiencia del especialista. Esto hace de la radiografía de tórax un caso atractivo para sistemas de apoyo al diagnóstico basados en inteligencia artificial.

Este proyecto busca desarrollar un sistema que reciba una radiografía de tórax en formato DICOM, la procese con un modelo de Deep Learning y entregue al usuario (i) las patologías probables presentes en la imagen y (ii) su ubicación aproximada sobre la radiografía. El modelo se entrenará con el dataset público **NIH ChestX-ray14** [1], que contiene 112.120 radiografías frontales de 30.805 pacientes, con etiquetas para 14 categorías de patologías torácicas.

El sistema se concibe como una **herramienta de apoyo y prototipo académico**, no como un dispositivo de diagnóstico: cualquier resultado debe ser revisado por un profesional de la salud.

Este documento corresponde al Hito 1 y cubre la planificación, el análisis de requisitos, el diseño de la arquitectura modular, el diseño de interfaces (mockups) y el diseño de pruebas. Las referencias se listan en la sección 12.

1.1. Objetivos

1. **O1.** Analizar y preparar el dataset NIH ChestX-ray14, respetando la división por paciente, para disponer de conjuntos de entrenamiento, validación y prueba reproducibles.

2. **O2.** Entrenar un modelo de clasificación multi-etiqueta de 14 patologías y evaluarlo con AUC-ROC por patología sobre el conjunto de prueba.

3. **O3.** Implementar un método de localización de las regiones afectadas y evaluarlo con las cajas delimitadoras disponibles (IoU).

4. **O4.** Desarrollar una aplicación con interfaz gráfica que reciba una imagen DICOM, ejecute el modelo y muestre patologías y ubicación.

5. **O5.** Diseñar y ejecutar un plan de pruebas que verifique los requisitos funcionales y no funcionales del sistema.

2. Diagnóstico e identificación del problema, desafío u oportunidad

Problema. El diagnóstico de patologías pulmonares a partir de radiografías de tórax es difícil y variable. Los síntomas clínicos suelen ser inespecíficos (por ejemplo, la neumonía puede confundirse con un resfrío o una gripe), por lo que el médico integra antecedentes, examen físico y estudios de imagen. Dentro de ese proceso, la radiografía aporta evidencia visual directa de la afectación pulmonar, pero su lectura es exigente y puede variar entre observadores. Además, un mismo paciente puede presentar varias patologías a la vez, como muestra la matriz de co-ocurrencia del dataset, lo que complica aún más la interpretación.

Desafío. Construir un modelo que no solo clasifique, sino que también localice la región afectada, con la limitación de que el dataset dispone de etiquetas por imagen y de solo ∼1.000 imágenes con cajas delimitadoras (bounding boxes). Además, las etiquetas fueron extraídas de informes radiológicos mediante procesamiento de lenguaje natural (NLP), con una exactitud estimada superior al 90 % [1], por lo que contienen algo de ruido. Otros desafíos son el desbalance entre clases (por ejemplo, Infiltration aparece en 19.894 imágenes (17,74 %) frente a 227 de Hernia (0,20 %), y el 53,84 % de las imágenes no tiene hallazgos) y la diferencia entre el formato de entrenamiento (PNG de 1024×1024) y el formato de uso real (DICOM).

Oportunidad. NIH ChestX-ray14 es uno de los mayores conjuntos públicos de radiografías de tórax, con cerca de 27 veces más imágenes frontales que el dataset previo Open-i [1]. Esto permite entrenar redes profundas con volúmenes de datos adecuados y disponer de una división oficial por paciente (entrenamiento/validación y prueba). Con ello es viable desarrollar un prototipo completo, desde el entrenamiento hasta una interfaz que acepte DICOM, y evaluar su desempeño con métricas estándar.

3. Propuesta de solución

El qué. Un sistema compuesto por (a) un modelo de Deep Learning multi-etiqueta que estima la probabilidad de cada una de las 14 patologías y (b) una aplicación con interfaz gráfica donde el usuario carga una radiografía DICOM, visualiza la imagen, y obtiene las patologías detectadas junto con su ubicación marcada sobre la imagen.

El cómo.

1. **Preparación de datos:** uso de `Data_Entry_2017.csv`, `train_val_list.txt` y `test_list.txt`, respetando la división por paciente para evitar fuga de información entre entrenamiento y prueba.
2. **Modelo de clasificación:** red convolucional preentrenada (por ejemplo, una familia DenseNet, como en trabajos previos sobre este dataset [2]) con transferencia de aprendizaje y salida de 14 neuronas con activación sigmoide y pérdida binaria por clase.
3. **Localización:** mapas de activación de clase (por ejemplo, Grad-CAM [3]) para obtener regiones de interés, convertidas en cajas delimitadoras. Las ∼1.000 imágenes con cajas reales se usarán para evaluar (y, si es posible, ajustar) la calidad de la localización.
4. **Aplicación:** lectura de DICOM, conversión a la entrada del modelo, inferencia, y visualización de resultados.

Alcance del Hito 1. Planificación, análisis, diseño y diseño de pruebas. El entrenamiento y la aplicación completos se desarrollan en los hitos siguientes. Queda fuera del alcance cualquier uso clínico real, el manejo de datos de pacientes reales y la certificación médica.

Límites del problema. El grupo definió en conjunto hasta dónde llega el proyecto:

- **Datos:** el modelo se entrena solo con NIH ChestX-ray14, con radiografías frontales. Las etiquetas vienen de informes mediante NLP, con exactitud estimada superior al 90 % [1], y las cajas delimitadoras son pocas (984) y cubren 8 de las 14 patologías.
- **Clínico:** el sistema analiza solo la imagen. No usa antecedentes, síntomas ni examen físico del paciente, que son parte del diagnóstico real, y no reemplaza al profesional de la salud.
- **Técnico:** la localización es aproximada, porque se estima con mapas de activación y no con un detector entrenado para todas las patologías. Se espera menor desempeño en las clases poco frecuentes, como Hernia.
- **Validación:** los resultados se miden sobre el conjunto de prueba del propio dataset. No se valida con radiólogos ni con datos de otros hospitales.
- **Fuera de alcance:** uso clínico real, manejo de datos de pacientes reales y certificación médica.

Contexto y trabajos previos. El dataset fue introducido por Wang et al. [1], que reportan clasificación y localización débilmente supervisada. Desde entonces se han propuesto modelos como CheXNet [2], que alcanzó desempeño comparable al de radiólogos en la detección de neumonía.

4. Estado del Arte y de la Técnica

Datasets. ChestX-ray8/14 [1] es el conjunto de referencia por su tamaño, aunque sus etiquetas provienen de NLP y tiene pocas cajas delimitadoras. Challenges como el de detección de neumonía de la RSNA (2018) aportaron anotaciones de localización para una sola patología y sirven como referencia de evaluación de detección.

Clasificación. Wang et al. [1] establecieron los primeros resultados de referencia sobre las 14 patologías. CheXNet [2] usó una DenseNet-121 [4] para detectar neumonía y luego las 14 patologías, y es hoy una línea base habitual.

Localización. Dado que hay pocas cajas anotadas, la localización suele hacerse de forma débilmente supervisada con mapas de activación (CAM, Grad-CAM [3]). Como alternativa, con más anotaciones se pueden usar detectores como Faster R-CNN [5] o YOLO.

Formato DICOM. El estándar DICOM [6] almacena la imagen junto con metadatos clínicos y puede incluir interpretaciones fotométricas (MONOCHROME1/2) y escalas de intensidad que requieren normalización antes de la inferencia. Se utilizará una librería como `pydicom` para su lectura.

Técnicas a utilizar: transferencia de aprendizaje, aumento de datos moderado, pérdida ponderada para el desbalance de clases, métricas AUC-ROC por patología e IoU para localización.

Limitaciones conocidas del dataset [1]: etiquetas con ruido por extracción NLP, pocas cajas delimitadoras y ausencia de los informes radiológicos originales.

5. Requisitos del Sistema

5.1. Requisitos Funcionales

- **RF1 – Cargar imagen DICOM:** el usuario puede seleccionar un archivo DICOM (.dcm) desde su equipo.
- **RF2 – Validar archivo:** el sistema verifica que el archivo sea un DICOM válido de radiografía de tórax y avisa si no lo es.
- **RF3 – Visualizar imagen:** el sistema muestra la radiografía cargada.
- **RF4 – Preprocesar imagen:** el sistema convierte la imagen DICOM al formato de entrada del modelo (escala de intensidad, tamaño y normalización).
- **RF5 – Detectar patologías:** el sistema estima la probabilidad de cada una de las 14 patologías del dataset.
- **RF6 – Localizar patologías:** el sistema indica sobre la imagen la región asociada a cada patología detectada.
- **RF7 – Mostrar resultados:** el sistema lista las patologías sobre un umbral, con su probabilidad, y superpone las regiones sobre la imagen.
- **RF8 – Ajustar umbral:** el usuario puede cambiar el umbral de decisión para mostrar más o menos patologías.
- **RF9 – Exportar resultados:** el usuario puede guardar la imagen anotada y un resumen de resultados.
- **RF10 – Entrenar y evaluar el modelo:** el equipo puede entrenar el modelo y obtener métricas sobre el conjunto de prueba (módulo de desarrollo, no visible al usuario final).

5.2. Requisitos no funcionales

- **RNF1 – Rendimiento:** la inferencia sobre una imagen debe tardar menos de 10 segundos en el equipo objetivo.
- **RNF2 – Usabilidad:** un usuario sin conocimientos técnicos debe poder obtener un resultado en no más de 3 pasos.
- **RNF3 – Portabilidad:** la aplicación debe ejecutarse en Windows y Linux con Python.
- **RNF4 – Mantenibilidad:** el código debe ser modular, documentado y versionado en un repositorio.
- **RNF5 – Privacidad y seguridad:** las imágenes se procesan localmente y no se envían a servicios externos; no se almacenan datos de pacientes sin acción del usuario.
- **RNF6 – Reproducibilidad:** el entrenamiento debe poder repetirse fijando semillas y registrando la configuración.
- **RNF7 – Transparencia:** la interfaz debe indicar que el resultado es un apoyo y no un diagnóstico médico.
- **RNF8 – Desempeño del modelo (meta inicial):** AUC-ROC promedio sobre las 14 patologías cercano a lo reportado en la literatura para este dataset [1][2]; la meta definitiva se fijará tras el primer entrenamiento base.

5.3. Requisitos de Interfaces

Cuadro 1: Eventos externos

Evento	Descripción	Iniciador	Parámetros	Respuesta
Cargar DICOM	El usuario selecciona un archivo .dcm	Usuario	Ruta del archivo	R1
Analizar imagen	El usuario solicita ejecutar el modelo	Usuario	Imagen cargada, umbral	R2
Cambiar umbral	El usuario modifica el umbral de decisión	Usuario	Valor del umbral (0–1)	R3
Exportar	El usuario guarda los resultados	Usuario	Ruta de destino	R4
Archivo inválido	El archivo no es un DICOM válido	Sistema de archivos	Archivo	R5

Cuadro 2: Respuestas del sistema

Respuesta	Descripción	Parámetros
R1	Muestra la imagen cargada y habilita el botón de análisis	Imagen, metadatos básicos
R2	Muestra el listado de patologías con probabilidad y la imagen con regiones superpuestas	Probabilidades, regiones
R3	Actualiza el listado y las regiones mostradas según el nuevo umbral	Umbral
R4	Guarda la imagen anotada y el resumen de resultados	Archivos de salida
R5	Muestra un mensaje de error y no ejecuta el análisis	Mensaje de error

La interfaz de entrada respeta el estándar DICOM [6].

6. Requisitos de Ambiente

6.1. Hardware de Desarrollo

- Computadores personales de los integrantes para desarrollo de código y la aplicación.
- GPU para entrenamiento (por definir: equipo local con GPU dedicada o servicio en la nube). Esto debe confirmarse antes del Hito 2, pues el entrenamiento sobre 112.120 imágenes es costoso.
- Almacenamiento suficiente para el dataset (112.120 imágenes PNG de 1024×1024).

6.2. Software de Desarrollo

- Python 3, con PyTorch (o TensorFlow/Keras) para el modelo.
- `pydicom` para lectura de DICOM; OpenCV/Pillow para procesamiento de imágenes.
- Pandas y scikit-learn para manejo de metadatos y métricas.
- Framework de interfaz gráfica (por definir: PyQt, Tkinter o aplicación web local con Streamlit/Gradio).
- Git y un repositorio compartido para control de versiones; herramienta de gestión de tareas para la bitácora.

6.3. Datasets e Imágenes/Videos de Prueba

NIH ChestX-ray14 [1]:

- 112.120 imágenes frontales PNG de 1024×1024 de 30.805 pacientes, con 14 etiquetas de patologías (multi-etiqueta).
- `Data_Entry_2017.csv`: índice de imagen, etiquetas, seguimiento, ID de paciente, edad, sexo, posición de la vista y tamaño y espaciado de píxel originales.
- `BBox_List_2017.csv`: cajas delimitadoras (x, y, w, h) para ∼1.000 imágenes.

- `train_val_list.txt` y `test_list.txt`: división por paciente.

Plan de uso: entrenamiento con la parte de entrenamiento, validación separando pacientes (no imágenes) del conjunto train_val, y evaluación final solo con test_list. Las imágenes con cajas se usarán para evaluar la localización. Para probar la aplicación con DICOM se buscarán radiografías de tórax DICOM de uso público, o se convertirán imágenes del dataset a DICOM con fines de prueba, lo que debe validarse como parte del diseño de pruebas.

Cuadro 3: Distribución de diagnósticos y cajas delimitadoras (112.120 imágenes)

Diagnóstico	Imágenes	% del total	Cajas delimitadoras
No Finding (sin hallazgos)	60.361	53,84 %	—
Infiltration	19.894	17,74 %	123
Effusion	13.317	11,88 %	153
Atelectasis	11.559	10,31 %	180
Nodule	6.331	5,65 %	79
Mass	5.782	5,16 %	85
Pneumothorax	5.302	4,73 %	98
Consolidation	4.667	4,16 %	—
Pleural_Thickening	3.385	3,02 %	—
Cardiomegaly	2.776	2,48 %	146
Emphysema	2.516	2,24 %	—
Edema	2.303	2,05 %	—
Fibrosis	1.686	1,50 %	—
Pneumonia	1.431	1,28 %	120
Hernia	227	0,20 %	—
Total de cajas			**984**

Las imágenes pueden tener varias etiquetas, por lo que los porcentajes no suman 100 %. En el archivo de cajas la categoría Infiltration figura como "Infiltrate". Los conteos se obtuvieron de `Data_Entry_2017.csv` y `BBox_List_2017.csv` y se guardaron en `frecuencia_diagnosticos.csv` y `frecuencia_bboxes.csv`.

Tres consecuencias para el diseño:

- **Desbalance fuerte:** Infiltration tiene unas 88 veces más imágenes que Hernia (19.894 contra 227). Por eso se usará pérdida ponderada por clase y se reportará el AUC-ROC de cada patología, no solo el promedio.
- **Localización parcial:** las cajas cubren solo 8 de las 14 patologías. Consolidation, Pleural_Thickening, Emphysema, Edema, Fibrosis y Hernia no tienen cajas, así que su ubicación solo puede estimarse con Grad-CAM y no puede evaluarse con IoU.
- **Clase "No Finding":** el 53,84 % de las imágenes no tiene hallazgos. El modelo mantiene 14 salidas y trata una imagen sana como aquella donde todas las probabilidades son bajas.

6.4. Perfiles de Usuario

Cuadro 4: Perfiles de usuario

Perfil	Socioeconómico y cultural	Ocupacional	Etario	Características físicas, fisiológicas, psicológicas	Otros
Médico radiólogo / especialista	General	Profesional de la salud que interpreta imágenes	Adulto	Sin restricciones particulares; requiere visualización de alta calidad	Usa el sistema como segunda opinión
Médico de urgencias / general	General	Profesional que decide con rapidez ante la sospecha de patología pulmonar	Adulto	Trabaja bajo presión de tiempo	Requiere resultados rápidos y claros
Estudiante o investigador	General	Estudiante de medicina, ingeniería o investigador en IA médica	Joven adulto / adulto	Sin restricciones particulares	Usa el sistema con fines docentes o de evaluación

7. Planificación del Proyecto

7.1. Objetivo General (Goal)

Desarrollar un sistema de apoyo al análisis de radiografías de tórax, basado en Deep Learning, que detecte patologías pulmonares y su ubicación a partir de una imagen DICOM, utilizando el dataset NIH ChestX-ray14.

7.2. Objetivos Específicos

Ver sección 1.1.

7.3. Actividades y Milestones

Semanas y fechas según el calendario del curso (la semana 10 es del 05/10 al 09/10). El detalle por tarea, con su entregable, está en la Bitácora 1. Responsables, fechas y avances son una propuesta que el equipo debe confirmar.

Cuadro 5: Actividades y milestones

Elemento	Responsable	Participación equipo	Fecha comienzo	Fecha término	% avance
A1.1 Análisis del dataset y estadísticas de clases (O1)	Nicolas Severino	25 % c/u	21/09 (S8)	02/10 (S9)	100 %
A1.2 Pipeline de datos: división por paciente y preprocesamiento (O1)	Benjamin Arias	25 % c/u	12/10 (S11)	23/10 (S12)	0 %
A2.1 Modelo base: entorno, clasificador DenseNet121 y primer entrenamiento (O2)	Hans Varela	25 % c/u	12/10 (S11)	06/11 (S14)	0 %
A2.2 Ajuste de hiperparámetros y evaluación AUC-ROC (O2)	Hans Varela	25 % c/u	02/11 (S14)	20/11 (S16)	0 %
A3.1 Localización con Grad-CAM, cajas e IoU (O3)	Karime Jarufe	25 % c/u	02/11 (S14)	20/11 (S16)	0 %
A4.1 Lectura y preprocesamiento de DICOM (O4)	Benjamin Arias	25 % c/u	12/10 (S11)	30/10 (S13)	0 %
A4.2 Interfaz gráfica: mockups, implementación e integración (O4)	Karime Jarufe	25 % c/u	28/09 (S9)	27/11 (S17)	33 %
A5.1 Diseño del plan de pruebas (O5)	Nicolas Severino	25 % c/u	28/09 (S9)	09/10 (S10)	100 %
A5.2 Ejecución de pruebas e informe final (O5)	Nicolas Severino	25 % c/u	02/11 (S14)	04/12 (S18)	0 %
G1.1 Gestión: documento, presentaciones, bitácoras y reuniones semanales	Todo el equipo	25 % c/u	21/09 (S8)	04/12 (S18)	43 %
G1.2 Definición y delimitación del problema: alcance, supuestos y límites	Todo el equipo	25 % c/u	21/09 (S8)	02/10 (S9)	100 %

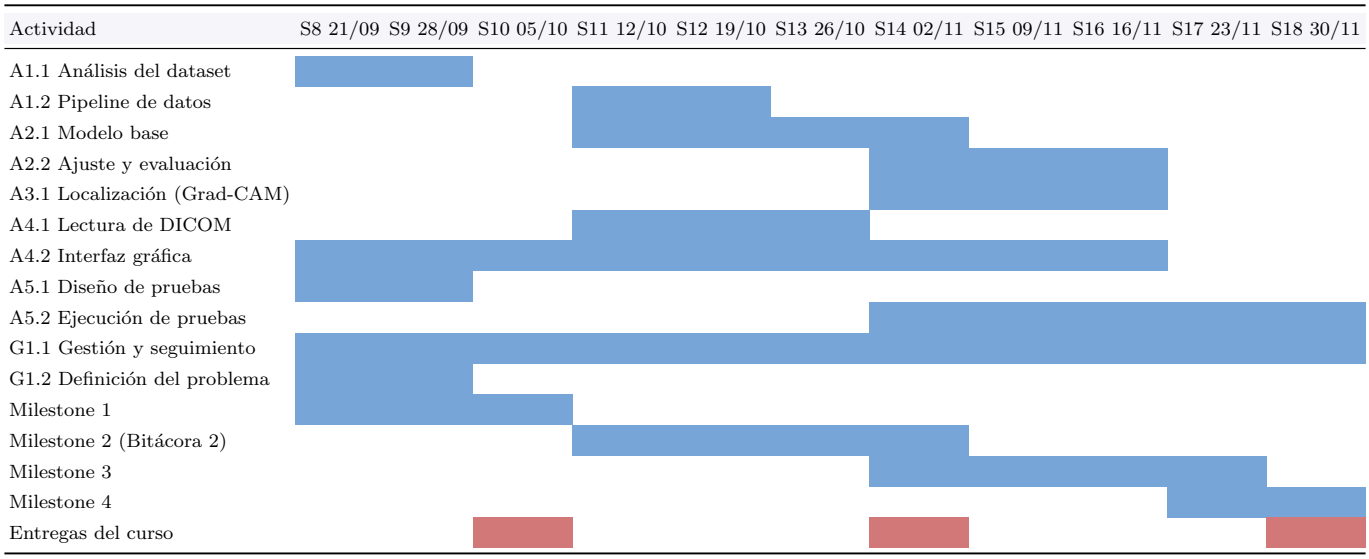
Continúa en la página siguiente...

Elemento	Responsable	Participación equipo	Fecha comienzo	Fecha término	% avance
Milestone 1: Análisis y Diseño (documento, presentación y Bitácora 1)	Todo el equipo	25 % c/u	21/09 (S8)	09/10 (S10)	100 %
Milestone 2 (Bitácora 2): avance con modelo base entrenado y lector DICOM	Todo el equipo	25 % c/u	12/10 (S11)	06/11 (S14)	0 %
Milestone 3: sistema integrado con localización e interfaz	Todo el equipo	25 % c/u	02/11 (S14)	27/11 (S17)	0 %
Milestone 4: presentación en la Feria y evaluación final (Bitácora 3)	Todo el equipo	25 % c/u	23/11 (S17)	04/12 (S18)	0 %

7.4. Carta Gantt

Planificación por semana del calendario del curso: S10 (05/10) es la semana de la Bitácora 1, S14 (02/11) la de la Bitácora 2 y S18 (30/11) la de la Feria y la Bitácora 3. ■ = planificado; = entrega del curso. La semana 11 parte con feriado el lunes 12/10, y la semana 17 es de trabajo de proyecto sin clases. Las actividades cumplidas deben actualizarse con el tiempo real empleado.

Cuadro 6: Carta Gantt



8. Diseño de Arquitectura del Sistema

8.1. Diagrama de Contexto

El sistema se modela como una caja negra con los siguientes entes externos:

- **Usuario** → Sistema: archivo DICOM, umbral de decisión, órdenes de análisis y exportación.
- **Sistema** → Usuario: patologías detectadas con probabilidad, imagen con regiones marcadas, mensajes de estado y error.
- **Sistema de archivos** → Sistema: archivos DICOM y pesos del modelo entrenado; Sistema → **Sistema de archivos**: resultados exportados.
- **Dataset NIH ChestX-ray14** → Sistema (solo en la fase de desarrollo): imágenes, etiquetas y cajas delimitadoras para entrenamiento y evaluación.

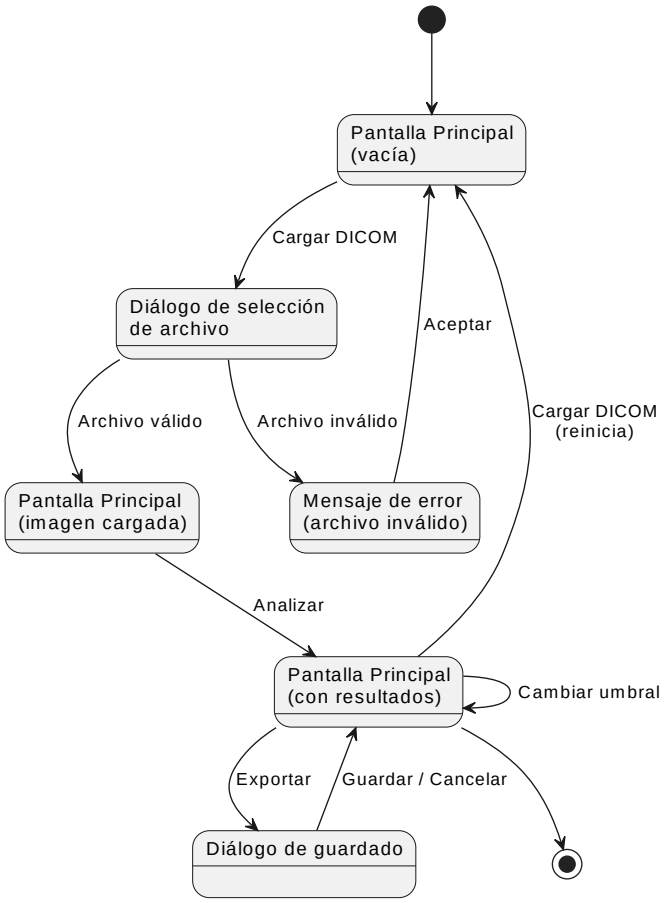


Figura 1: Diagrama de contexto.

8.2. Diagrama de Arquitectura

Flujo principal de información entre módulos:

GUI → DCM (archivo DICOM) → PRE (imagen normalizada) → CLS (probabilidades por patología) → LOC (mapas y cajas) → GUI (resultados).

En la fase de desarrollo, TRN usa PRE para entrenar y evaluar a CLS y LOC, y entrega los pesos del modelo.

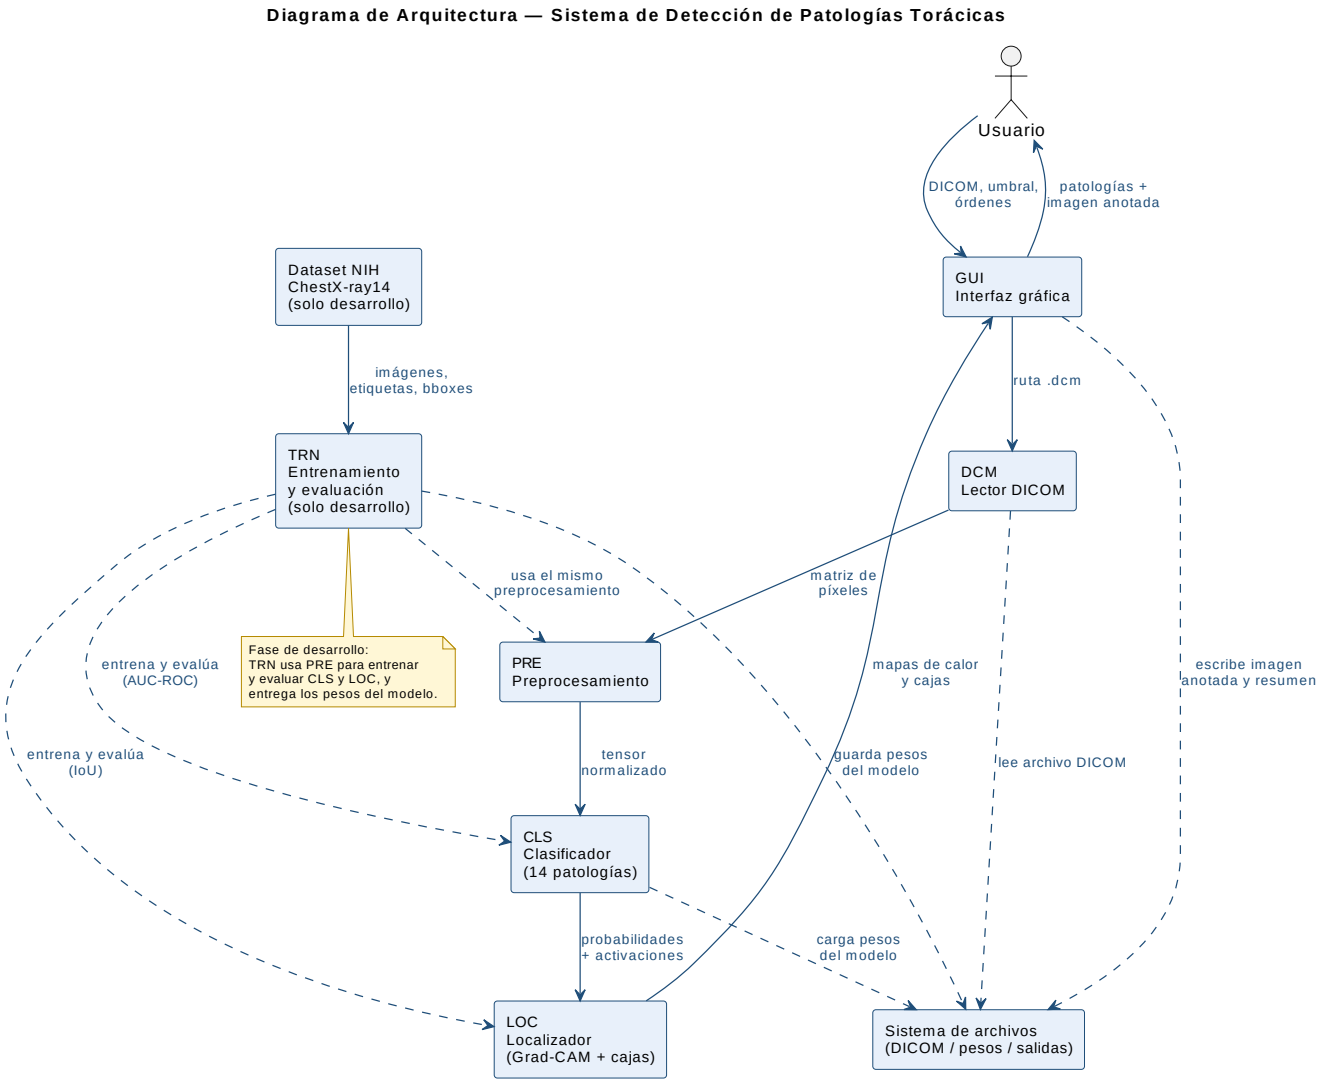


Figura 2: Diagrama de arquitectura, a incorporar como figura en la versión con gráficos.

8.3. Enumeración de Módulos

Cuadro 7: Módulos de la arquitectura del sistema

Módulo	Propósito	Sección
Lector DICOM (DCM)	Lee y valida el archivo DICOM, extrae la matriz de píxeles y los metadatos relevantes.	9.5
Preprocesamiento (PRE)	Convierte la imagen al formato de entrada del modelo: corrección de interpretación fotométrica, escalado de intensidad, redimensionamiento y normalización. Se usa tanto en entrenamiento como en inferencia.	9.5
Clasificador (CLS)	Modelo convolucional que entrega la probabilidad de cada una de las 14 patologías.	9.5
Localizador (LOC)	Genera mapas de activación a partir del clasificador y los convierte en regiones o cajas sobre la imagen.	9.5
Interfaz gráfica (GUI)	Permite cargar la imagen, lanzar el análisis, ajustar el umbral y ver y exportar los resultados.	10
Entrenamiento y evaluación (TRN)	Gestiona los datos del dataset, entrena el modelo y calcula métricas (AUC-ROC, IoU).	9.5

8.4. Matriz de Requisitos Funcionales y Módulos

Cuadro 8: Matriz de requisitos funcionales y módulos

Requisito	DCM	PRE	CLS	LOC	GUI	TRN
RF1 Cargar DICOM	X				X	
RF2 Validar archivo	X				X	
RF3 Visualizar imagen					X	
RF4 Preprocesar imagen		X				
RF5 Detectar patologías			X			
RF6 Localizar patologías				X		
RF7 Mostrar resultados					X	
RF8 Ajustar umbral					X	
RF9 Exportar resultados					X	
RF10 Entrenar y evaluar		X	X	X		X

No hay filas ni columnas vacías. La mayor concentración está en la GUI, lo que es esperable porque agrupa todas las funciones de interacción con el usuario.

8.5. Definición de Módulos

Se sigue un diseño modular orientado a objetos: cada módulo se implementa como una clase con una interfaz acotada, de modo que se puedan reemplazar componentes (por ejemplo, cambiar el modelo o el método de localización) sin afectar al resto.

8.5.0.1 Módulo DCM – Lector DICOM.

- **Propósito:** leer un archivo DICOM y entregar una matriz de píxeles y metadatos.
- **General:** entra la ruta del archivo; sale la imagen en escala de grises y los metadatos (interpretación fotométrica, tamaño, espaciado de píxel) o un error de validación.
- **Marco técnico:** estándar DICOM [6], librería `pydicom`; manejo de MONOCHROME1 (invertir) y MONOCHROME2.
- **Estructura general:** `DicomReader.load(path) ->validate() ->to_array()`.

8.5.0.2 Módulo PRE – Preprocesamiento.

- **Propósito:** dejar toda imagen en el mismo formato de entrada del modelo, sin importar si viene de DICOM o del dataset.
- **General:** entra una matriz de píxeles; sale un tensor normalizado.
- **Marco técnico:** escalado de intensidad a rango de 8 bits, redimensionamiento (por ejemplo, 224×224 o 320×320), normalización por media y desviación estándar, aumento de datos en entrenamiento. Un punto crítico de diseño: el modelo se entrena con PNG de 8 bits, por lo que el DICOM de 12–16 bits debe reducirse de forma consistente para evitar diferencias entre entrenamiento y uso real.
- **Estructura general:** `Preprocessor.transform(array, train=False)`.

8.5.0.3 Módulo CLS – Clasificador.

- **Propósito:** estimar la probabilidad de cada patología.
- **General:** entra el tensor de imagen; salen 14 probabilidades.
- **Marco técnico:** red convolucional preentrenada (por ejemplo, DenseNet-121 [4]) con capa final de 14 salidas y activación sigmoide; pérdida binaria con ponderación por clase para el desbalance.
- **Estructura general:** `Classifier.predict(tensor) ->vector de 14 probabilidades`; `Classifier.load_weights(pa`

8.5.0.4 Módulo LOC – Localizador.

- **Propósito:** indicar dónde está la región asociada a cada patología detectada.
- **General:** entran el tensor de imagen y el clasificador; salen mapas de calor y cajas delimitadoras por patología sobre el umbral.
- **Marco técnico:** Grad-CAM [3] sobre la última capa convolucional; binarización del mapa y obtención de la caja que encierra la región principal.
- **Estructura general:** `Localizer.heatmap(tensor, class_id) ->Localizer.to_boxes(heatmap, threshold)`.

8.5.0.5 Módulo TRN – Entrenamiento y evaluación.

- **Propósito:** entrenar y evaluar el modelo.
- **General:** entran el dataset y la configuración; salen pesos del modelo y métricas.
- **Marco técnico:** división por paciente, validación interna, AUC-ROC por patología, IoU sobre las cajas anotadas.
- **Estructura general:** `Trainer.fit() ->Trainer.evaluate() ->Trainer.save()`.

(Esta sección crecerá a medida que se desarrolle la solución; en el Hito 1 corresponde al diseño general.)

9. Diseño de Interfaces

9.1. Modelo de Navegación

El punto de partida es la **Pantalla Principal**. La aplicación es de una sola ventana principal con un diálogo auxiliar:

1. **Pantalla Principal (vacía)** → evento *Cargar DICOM* → **Diálogo de selección de archivo**.
2. Diálogo de selección → archivo válido → **Pantalla Principal (imagen cargada)**; archivo inválido → **Mensaje de error** → vuelve a la Pantalla Principal.
3. Pantalla Principal (imagen cargada) → evento *Analizar* → **Pantalla Principal (con resultados)**.
4. Pantalla Principal (con resultados) → *Cambiar umbral* → se actualiza la misma pantalla; *Exportar* → **Diálogo de guardado** → vuelve a la pantalla; *Cargar DICOM* → reinicia el flujo.

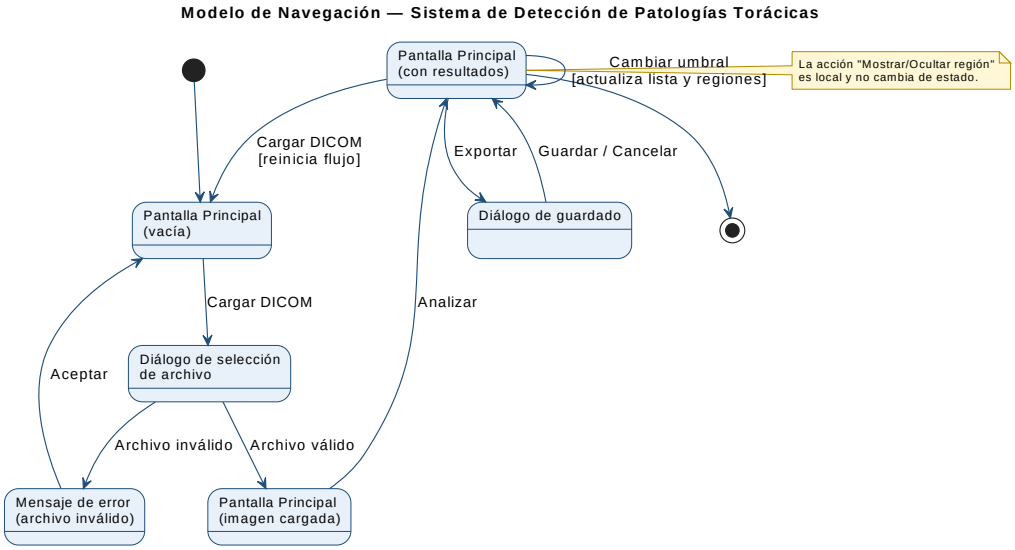


Figura 3: Diagrama de Modelo de Navegación

9.2. Prototipos de Interfaces Usuarias

9.2.0.1 Prototipo 1 – Pantalla Principal.

Diseño propuesto (mockup, no funcional): ventana dividida en tres zonas.

- **Izquierda:** visor de la radiografía, con las regiones detectadas superpuestas como cajas de colores con la etiqueta de la patología.
- **Derecha:** panel de resultados con la lista de patologías, su probabilidad (barra y porcentaje) y una casilla para mostrar u ocultar cada región.
- **Inferior:** botones *Cargar DICOM*, *Analizar*, *Exportar*, un control deslizante *Umbral*, y una barra de estado con un aviso permanente: “Herramienta de apoyo; no reemplaza el diagnóstico médico”.

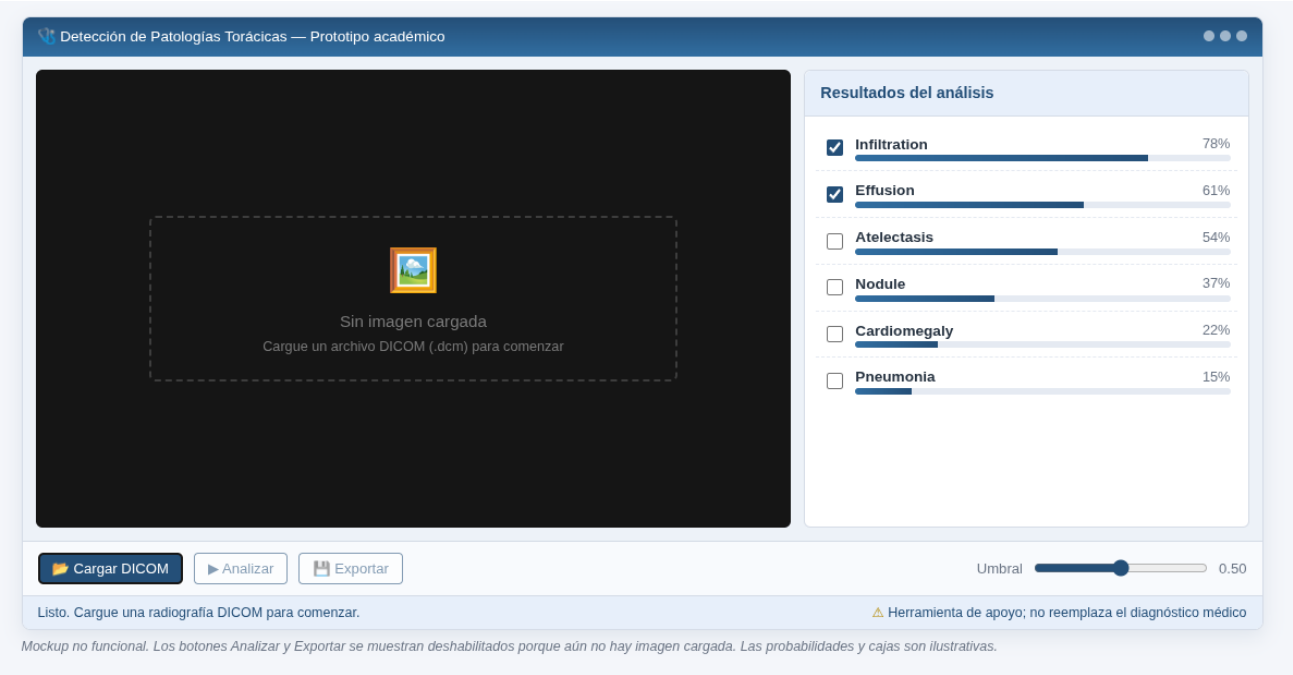


Figura 4: Prototipo 1 – Pantalla Principal.

Cuadro 9: Interacciones de la pantalla principal

Evento	Interacción	Acción	Objeto afectado
Cargar DICOM	Clic en el botón “Cargar DICOM”	Se abre el diálogo de selección; si el archivo es válido se muestra la imagen	Visor de radiografía
Analizar	Clic en el botón “Analizar”	Se ejecuta el modelo y se llenan los resultados	Panel de resultados, visor
Cambiar umbral	Mover el control deslizante “Umbral”	Se actualizan la lista y las regiones mostradas	Panel de resultados, visor
Mostrar/ocultar región	Marcar o desmarcar la casilla de una patología	Se muestra u oculta su región sobre la imagen	Visor de radiografía
Exportar	Clic en el botón “Exportar”	Se abre el diálogo de guardado y se guardan imagen anotada y resumen	Archivos de salida

9.2.0.2 Prototipo 2 – Mensaje de error.

Ventana emergente simple con el texto del problema (por ejemplo, “El archivo no es un DICOM válido de radiografía de tórax”) y un botón *Aceptar*.



Figura 5: Prototipo 2 – Mensaje de error

Cuadro 10: Interacción del mensaje de error

Evento	Interacción	Acción	Objeto afectado
Aceptar	Clic en “Aceptar”	Se cierra el mensaje y se vuelve a la Pantalla Principal	Ventana de mensaje

10. Diseño de Pruebas

Pruebas del modelo

Cuadro 11: Pruebas del modelo

ID	Prueba	Criterio de aceptación
PM1	Verificar que no hay pacientes repetidos entre entrenamiento/validación y prueba	0 pacientes en común
PM2	AUC-ROC por patología sobre `test_list.txt`	Se reporta para las 14 patologías; promedio cercano a la literatura [1][2]
PM3	IoU de las cajas generadas contra las cajas reales (∼1.000 imágenes)	Se reporta IoU y proporción de aciertos a distintos umbrales
PM4	Reproducibilidad: dos entrenamientos con la misma semilla	Resultados equivalentes dentro de una tolerancia definida

Pruebas unitarias de módulos

Cuadro 12: Pruebas unitarias de módulos

ID	Prueba	Criterio de aceptación
PU1	DCM lee un DICOM válido (MONOCHROME1 y MONOCHROME2)	Matriz con dimensiones y rango esperados
PU2	DCM rechaza un archivo que no es DICOM	Error controlado
PU3	PRE entrega el mismo tamaño y rango de valores para PNG y DICOM	Tensores equivalentes
PU4	CLS entrega 14 valores entre 0 y 1	Dimensión y rango correctos
PU5	LOC entrega cajas dentro de los límites de la imagen	Coordenadas válidas

Pruebas de sistema e interfaz

Cuadro 13: Pruebas de sistema e interfaz

ID	Prueba	Criterio de aceptación
PS1	Flujo completo: cargar DICOM, analizar, ver resultados	Resultados en menos de 10 segundos (RNF1)
PS2	Cambiar el umbral	La lista y las regiones se actualizan
PS3	Exportar resultados	Se generan los archivos esperados
PS4	Cargar un archivo inválido	Mensaje de error, la aplicación no se cae
PS5	Prueba de usabilidad con usuarios del perfil objetivo	Completan la tarea en no más de 3 pasos (RNF2)

11. Conclusiones

El Hito 1 establece las bases de análisis y diseño del sistema de detección y localización de patologías torácicas. Se identificaron los principales desafíos del dataset NIH ChestX-ray14 (desbalance, ruido en etiquetas, localización parcial) y se definió una arquitectura modular que separa lectura DICOM, preprocesamiento, clasificación, localización, interfaz y entrenamiento. Los requisitos funcionales y no funcionales quedaron especificados, y el plan de pruebas cubre tanto el modelo como los módulos y el sistema completo.

12. Referencias

1. X. Wang, Y. Peng, L. Lu, Z. Lu, M. Bagheri y R. M. Summers, "ChestX-ray8: Hospital-scale chest X-ray database and benchmarks on weakly-supervised classification and localization of common thorax diseases," en *Proc. IEEE CVPR*, 2017, pp. 3462–3471. (arXiv:1705.02315)

2. P. Rajpurkar et al., "CheXNet: Radiologist-level pneumonia detection on chest X-rays with deep learning," arXiv:1711.05225, 2017.

3. R. R. Selvaraju et al., "Grad-CAM: Visual explanations from deep networks via gradient-based localization," en *Proc. IEEE ICCV*, 2017.

4. G. Huang, Z. Liu, L. van der Maaten y K. Q. Weinberger, "Densely connected convolutional networks," en *Proc. IEEE CVPR*, 2017.

5. S. Ren, K. He, R. Girshick y J. Sun, "Faster R-CNN: Towards real-time object detection with region proposal networks," en *Advances in Neural Information Processing Systems (NIPS)*, 2015.

6. NEMA, "Digital Imaging and Communications in Medicine (DICOM) Standard, PS3," National Electrical Manufacturers Association.

7. H.-C. Shin et al., "Learning to read chest X-rays: Recurrent neural cascade model for automated image annotation," en *Proc. IEEE CVPR*, 2016, pp. 2497–2506.